PROPOSAL FINAL PROJECT ANALISIS DATA PUBLIK

Analisis Faktor Demografi dan Akademik terhadap Tingkat Dropout Mahasiswa Menggunakan Classification Machine Learning

Disusun Untuk Memenuhi Tugas Mata Kuliah Pengantar Big Data

Dosen Pengampu : Nono Heryana

\

Disusun Oleh Kelompok 9 :

Fanisa Zahira Priyanka	2410631250050
Lulu Solikha	2410631250014

PRODI SISTEM INFORMASI

FAKULTAS ILMU KOMPUTER

UNIVERSITAS SINGAPERBANGSA KARAWANG

2026

DAFTAR ISI

BAB I
PENDAHULUAN..... 3
I. Rumusan Masalah.....3
II. Tujuan.....3
III. Pertanyaan Analitik.....3
BAB II
Deskripsi Dataset Publik (Data Card)..... 4
BAB III
Alasan Pemilihan Dataset, Potensi Bias, Sensitivitas, dan Izin Redistribusi..... 5
I. Alasan Pemilihan Dataset.....5
II. Potensi Bias.....5
III. Sensitivitas Data.....5
IV. Izin Redistribusi (GitHub).....6
BAB IV
Ringkasan Teori dan Penelitian Terdahulu.....6
I. Ringkasan Teori.....6
II. Penelitian Terdahulu.....6
BAB V
Metodologi dan Perencanaan Proyek..... 7
I. Metode Deskriptif.....7
II. Metode Lanjutan..... 7
III. Baseline.....8
IV. Metrik Evaluasi..... 8
REFERENSI..... 9

BAB I
PENDAHULUAN

I. Rumusan Masalah

Tingkat putus kuliah (*dropout*) mahasiswa terus menjadi persoalan serius di perguruan tinggi karena tidak hanya merugikan mahasiswa secara individu, tetapi juga membebani institusi dalam hal akreditasi dan efisiensi biaya. Pendekatan konvensional yang hanya mengandalkan nilai ujian seringkali terlambat dalam mendeteksi potensi *dropout*. Oleh karena itu, dibutuhkan sebuah model analitik prediktif yang menggabungkan faktor akademik, demografis, dan sosio-ekonomi untuk mengidentifikasi mahasiswa berisiko sedini mungkin, sehingga intervensi yang tepat dapat segera diberikan.

II. Tujuan

Proyek akhir ini bertujuan untuk:

- Membangun model klasifikasi *Machine Learning* guna memprediksi status akhir mahasiswa (*Dropout, Enrolled,* atau *Graduate*).
- Mengidentifikasi fitur atau variabel paling berpengaruh yang menyebabkan seorang mahasiswa memutuskan untuk berhenti kuliah.
- Menyediakan fondasi data yang kuat bagi perguruan tinggi untuk merancang sistem peringatan dini (*Early Warning System*) berbasis data terbuka.

III. Pertanyaan Analitik

1. Faktor non-akademik apa saja (misalnya status utang, inflasi, atau riwayat pendidikan orang tua) yang memiliki korelasi terkuat terhadap keputusan *dropout*?
2. Sejauh mana performa pada dua semester pertama dapat dijadikan acuan valid untuk memprediksi kelulusan?
3. Apakah algoritma klasifikasi ensemble (seperti LightGBM atau Random Forest) mampu memberikan akurasi prediksi di atas 80% pada dataset yang memiliki ketidakseimbangan kelas (*imbalanced data*)?

IV. Unit Analisis: Unit analisis terfokus pada tingkat mahasiswa secara individu. Setiap baris data dalam dataset mewakili profil satu orang mahasiswa secara spesifik.

Pengguna Hasil: Pihak rektorat, dekanat, pembimbing akademik (dosen wali), serta tim penjaminan mutu perguruan tinggi yang bertugas merancang kebijakan retensi mahasiswa.

BAB II

Deskripsi Dataset Publik (Data Card)

Dataset yang digunakan merupakan data riil dari institusi pendidikan di Portugal yang sepenuhnya berstatus akses terbuka (*open access*) dan gratis untuk keperluan penelitian maupun pembelajaran.

- **Penerbit:** UCI Machine Learning Repository (Disumbangkan oleh Valentim Realinho, dkk. pada tahun 2021).
- **URL/DOI:** https://archive.ics.uci.edu/dataset/697/predict+students+dropout+and+academic+success
- **Lisensi:** Creative Commons Attribution 4.0 International (CC BY 4.0). Lisensi ini menjamin bahwa data ini gratis, terbuka, dan sah untuk diolah maupun dibagikan ulang.
- **Versi & Tahun Terbit:** Versi 1.0 (Dipublikasikan perdana pada akhir tahun 2021).
- **Tanggal Akses:** 6 September 2026.
- **Periode Data:** Data sekunder yang mencatat profil pendaftaran dan rekam akademik mahasiswa dari beberapa program studi sebelum tahun publikasinya (2021).
- **Atribut Utama:** Terdiri dari 36 atribut dan 4.424 baris data mahasiswa. Atribut dibagi ke dalam tiga pilar:
    - **Demografis & Makroekonomi:** Usia, gender, status perkawinan, latar belakang pekerjaan/pendidikan orang tua, serta indikator seperti tingkat pengangguran dan inflasi saat pendaftaran.
    - **Latar Belakang Pendaftaran:** Pilihan jalur masuk, program studi, status beasiswa, dan utang biaya kuliah.
    - **Performa Akademik:** Jumlah mata kuliah yang diambil, lulus, serta nilai (indeks prestasi) di semester pertama dan kedua.

- **Target:** Atribut label (Target) yang berisi tiga kelas kategorikal: Dropout, Enrolled, dan Graduate.

BAB III

Alasan Pemilihan Dataset, Potensi Bias, Sensitivitas, dan Izin Redistribusi

I. Alasan Pemilihan Dataset

Dataset ini dipilih karena benar-benar gratis dan mudah diakses secara global melalui portal UCI. Dari segi substansi, dataset ini sangat rapi (tidak memiliki nilai kosong yang merusak model) dan menawarkan kombinasi unik antara data akademik dan sosio-ekonomi, sehingga eksplorasi datanya bisa lebih dalam dibandingkan hanya menganalisis nilai IPK.

II. Potensi Bias

Data ini diambil secara spesifik dari satu perguruan tinggi di Portugal. Kondisi makroekonomi (seperti inflasi) dan regulasi pendidikannya tentu berbeda dengan konteks negara berkembang. Oleh karena itu, kesimpulan terkait dampak inflasi atau beasiswa mungkin mengandung bias wilayah (*geographic bias*) jika langsung disamakan dengan mahasiswa di tempat lain. Selain itu, porsi mahasiswa yang lulus lebih banyak daripada yang *dropout*, sehingga menimbulkan sedikit masalah ketidakseimbangan kelas (*imbalanced data*) yang perlu ditangani.

III. Sensitivitas Data

Meskipun mencakup data sosial ekonomi seperti utang kuliah, sensitivitas dataset ini berada pada level aman (rendah). Semua identitas pribadi (nama, alamat surel, nomor kartu identitas) telah dihapus dari awal (dianonimkan), sehingga sepenuhnya mematuhi prinsip privasi data riset.

IV. Izin Redistribusi (GitHub)

Dataset ini berlindung di bawah lisensi CC BY 4.0. Hal ini secara sah mengizinkan kelompok kami untuk menyimpan ulang sebagian data sampel, melakukan rilis tugas, dan mengunggahnya ke dalam *repository* GitHub publik, asalkan kutipan sitasi asli disertakan pada berkas README.md.

BAB IV
Ringkasan Teori dan Penelitian Terdahulu

I. Ringkasan Teori

Analisis ini didasarkan pada kerangka kerja *Educational Data Mining (EDM)* yang bertujuan untuk mengubah data transaksional kampus menjadi *insight* strategis. Pendekatan utamanya menggunakan *Supervised Machine Learning* kategori klasifikasi. Algoritma berbasis pohon (*tree-based algorithms*) seperti *Decision Tree*, *Random Forest*, dan *LightGBM* sangat direkomendasikan karena mereka mampu menangani relasi data non-linear tanpa memerlukan asumsi distribusi data yang rumit. Selain itu, fitur interpretasi (seperti *feature importance*) pada algoritma ini sangat mudah dibaca untuk mengetahui variabel apa yang paling memicu *dropout*.

II. Penelitian Terdahulu

Dua referensi utama di bawah ini bersumber dari jurnal akademik MDPI yang terbit dalam kurun waktu 5 tahun terakhir (2021-2025), tepatnya pada tahun 2023:

1. **Lee & Lee (2023)** melalui artikelnya di jurnal *Applied Sciences* menguji berbagai model *machine learning* (Logistic Regression, Random Forest, hingga LightGBM) untuk memprediksi probabilitas *dropout* mahasiswa. Riset mereka membuktikan bahwa model berbasis *boosting* (seperti LightGBM) cenderung memberikan skor F1 terbaik untuk kasus data yang sedikit timpang (*imbalanced*).
2. **Chung & Lee (2023)** dalam penelitiannya membuktikan bahwa faktor demografi (seperti asal wilayah dan latar belakang keluarga) jika dikombinasikan dengan riwayat akademik

dasar sudah sangat cukup untuk menjadi alarm bahaya sebelum seorang mahasiswa baru (*freshman*) memutuskan berhenti. Mereka menekankan bahwa analisis tidak boleh hanya bergantung pada satu jenis metrik saja.

BAB V

Metodologi dan Perencanaan Proyek

I. Metode Deskriptif

Kami akan memulainya dengan *Exploratory Data Analysis (EDA)*. Langkah ini meliputi pengecekan distribusi setiap atribut, mendeteksi pencilan (*outliers*), dan melihat korelasi bivariat. Misalnya, melihat rata-rata nilai semester pertama antara kelompok mahasiswa yang masih aktif dan yang sudah *dropout*.

Visualisasi:

- *Heatmap Korelasi:* Untuk memvisualisasikan fitur mana yang berkorelasi paling kuat dengan kolom target secara instan.
- *Bar Plot Bertumpuk (Stacked Bar):* Menunjukkan rasio kelulusan dan *dropout* di setiap program studi, sehingga terlihat jelas jurusan mana yang tingkat partisipasinya paling berisiko.
- *Feature Importance Chart:* Grafik pasca-pemodelan untuk menampilkan variabel teratas penyumbang *dropout* (misal: apakah tagihan utang lebih krusial dibandingkan IPK semester awal).

II. Metode Lanjutan

Kami berencana menggunakan algoritma klasifikasi ansambel seperti **Random Forest Classifier**. Algoritma ini dirancang dengan membangun ratusan pohon keputusan secara acak, yang kemudian hasilnya akan "divoting" bersama. Hal ini sangat efektif untuk mengurangi risiko kelebihan penyesuaian (*overfitting*) pada data edukasi.

III. Baseline

Sebagai tolok ukur atau *baseline*, kami akan menggunakan **Logistic Regression**. Algoritma ini lebih sederhana dan cepat; jika model *Random Forest* tidak mampu memberikan skor akurasi yang lebih baik secara signifikan dibandingkan *Logistic Regression*, maka beban komputasi tambahan menjadi tidak sepadan.

IV. Metrik Evaluasi

Mengingat distribusi target tidak seimbang (lulus lebih banyak dari *dropout*), metrik utama yang dinilai bukan sekadar Akurasi konvensional, melainkan **F1-Score** dan **Recall**. Nilai *Recall* (sensitivitas) untuk kelas *dropout* menjadi yang paling krusial karena kita ingin memastikan seminimal mungkin model gagal mendeteksi mahasiswa yang sebenarnya berpotensi putus kuliah.

Jadwal Pelaksanaan (4 Minggu):

Minggu	Rencana Kegiatan
1	Penyusunan final proposal, validasi ketersediaan dataset *open-access*, pembentukan repositori GitHub, dan pembagian peran.
2	Pembersihan data mentah (jika diperlukan), standardisasi format, serta pelaksanaan analisis deskriptif dan pembuatan visualisasi awal.
3	Pembagian data (*train-test split*), pelatihan model *baseline* (Logistic Regression), dan penerapan *Random Forest*.

Minggu	Rencana Kegiatan
4	Evaluasi nilai akhir model (F1-score dan Recall), interpretasi *insight* penelitian, penulisan laporan final, dan rilis *tag tugas-1* di GitHub.

Pembagian Tugas Kelompok (2 Anggota):

- **Anggota 1:** Bertanggung jawab penuh pada pengelolaan manajemen proyek (setup repositori, lisensi), penyusunan narasi proposal awal, tahapan pra-pemrosesan data (*data cleaning*), dan desain tata letak visualisasi deskriptif.
- **Anggota 2:** Berfokus pada pengerjaan inti pemrograman *Machine Learning*. Mengembangkan model klasifikasi prediktif, melakukan penyetelan parameter (*hyperparameter tuning*), perhitungan metrik evaluasi teknis, serta merumuskan analisis teoritis terkait *feature importance*.

REFERENSI

1. Realinho, V., Machado, J., Baptista, L., & Martins, M. V. (2021). *Predict Students' Dropout and Academic Success* [Dataset]. UCI Machine Learning Repository. DOI: https://doi.org/10.24432/C5MC89.
2. Lee, J. Y., & Lee, S. (2023). A Study on Dropout Prediction for University Students Using Machine Learning Techniques. *Applied Sciences*, 13(21), 12004. MDPI. DOI: https://doi.org/10.3390/app132112004.
3. Chung, J., & Lee, J. (2023). University Student Dropout Prediction Using Pretrained Language Models. *Applied Sciences*, 13(12), 7073. MDPI. DOI: https://doi.org/10.3390/app13127073