LAPORAN TASK 2
PENGANTAR BIG DATA

Analisis Faktor Demografi dan Akademik terhadap Tingkat Dropout Mahasiswa Menggunakan Classification Machine Learning

Disusun Untuk Memenuhi Tugas Mata Kuliah Pengantar Big Data

Dosen Pengampu : Nono Heryana, S.Kom., M.Kom.

Disusun Oleh Kelompok 9 :

Fanisa Zahira Priyanka — 2410631250050

Lulu Solikha — 2410631250014

PRODI SISTEM INFORMASI

FAKULTAS ILMU KOMPUTER

UNIVERSITAS SINGAPERBANGSA KARAWANG

2026

BAB I
PERSIAPAN DAN AKUISISI DATA

1.1 Akuisisi Dataset

Pada tahap pertama Task 2, saya menggunakan dataset yang sama dengan dataset yang telah digunakan pada Task 1, yaitu Predict Students' Dropout and Academic Success. Dataset tersebut diperoleh melalui UCI Machine Learning Repository dan digunakan sebagai sumber data utama untuk proses analisis pada tugas ini.

Dataset ini dipilih dan digunakan kembali karena sesuai dengan tujuan proyek kelompok, yaitu menganalisis faktor yang berkaitan dengan status akhir mahasiswa serta membangun pendekatan klasifikasi terhadap status tersebut. Berdasarkan dokumen proyek sebelumnya, unit analisis yang digunakan adalah mahasiswa secara individu, sehingga setiap baris pada dataset merepresentasikan satu mahasiswa.

Dataset yang digunakan terdiri dari 4.424 data mahasiswa dengan 36 atribut utama serta satu atribut target bernama Target. Variabel Target memiliki tiga kelas, yaitu Dropout, Enrolled, dan Graduate. Atribut yang tersedia mencakup informasi demografis, latar belakang pendaftaran, kondisi sosial ekonomi, serta performa akademik mahasiswa.

Sumber dataset yang digunakan adalah UCI Machine Learning Repository. Dataset tersebut diterbitkan oleh Realinho, Machado, Baptista, dan Martins pada tahun 2021 dengan lisensi Creative Commons Attribution 4.0 International (CC BY 4.0).

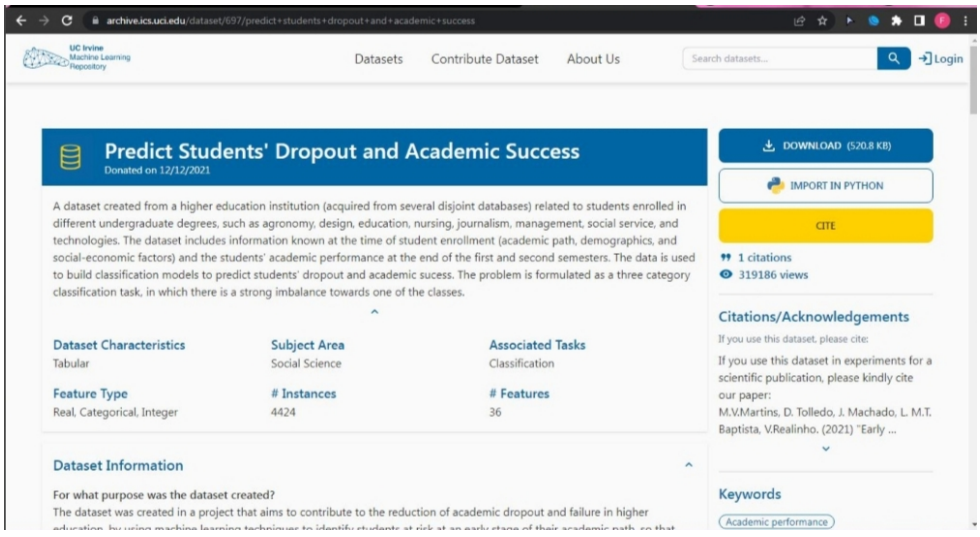
Langkah yang saya lakukan:

1. Membuka halaman resmi UCI Machine Learning Repository.
2. Mencari dataset dengan nama Predict Students' Dropout and Academic Success.
3. Mengunduh dataset dari sumber tersebut.

4. Setelah proses pengunduhan selesai, saya memeriksa file yang diperoleh untuk memastikan file dapat digunakan.
5. Tidak melakukan perubahan terhadap nilai maupun struktur data pada tahap akuisisi.
6. Dataset yang telah diperoleh kemudian digunakan sebagai raw data untuk tahap berikutnya.

Informasi sumber dataset

Informasi	**Keterangan**
Nama Dataset	Predict Students' Dropout and Academic Success
Sumber	UCI Machine Learning Repository
Dataset ID	697
Tahun	2021
DOI	10.24432/C5MC89
Jumlah Data	4.424 mahasiswa
Jumlah Atribut	36 atribut + 1 Target
Target	Dropout, Enrolled, Graduate
Lisensi	CC BY 4.0



Gambar 1. Halaman sumber dataset pada UCI Machine Learning Repository

2.1. Penyimpanan Raw Data

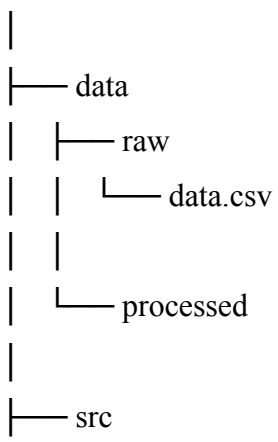
Setelah dataset berhasil diperoleh, saya menyimpan dataset tersebut sebagai raw data. Raw data merupakan data awal yang digunakan sebagai sumber sebelum dilakukan proses pengolahan atau transformasi. Pada tahap ini, saya mempertahankan isi dataset sebagaimana diperoleh dari sumber sehingga data asli tetap dapat digunakan sebagai acuan apabila diperlukan pada proses berikutnya.

File dataset yang saya gunakan bernama data.csv. Berdasarkan pemeriksaan terhadap file tersebut, dataset memiliki 4.424 baris dan 37 kolom. Dari 37 kolom tersebut, 36 kolom merupakan atribut atau variabel prediktor, sedangkan satu kolom yaitu Target digunakan sebagai variabel target.

File data.csv menggunakan tanda titik koma (;) sebagai pemisah antar kolom. Oleh karena itu, ketika file dibaca menggunakan perangkat lunak atau program pengolahan data, pemisah tersebut perlu dikenali sebagai delimiter agar struktur kolom dapat terbaca dengan benar.

Saya menyimpan file tersebut pada folder data/raw agar data mentah terpisah dari data hasil pengolahan. Pemisahan tersebut dilakukan untuk menjaga agar proses pengolahan pada tahap berikutnya tidak secara langsung mengubah file data asli.

Struktur folder yang digunakan adalah:



```
├── notebooks
├── figures
└── tables
    └── data_dictionary.xlsx
```

Pada tahap ini, saya tidak melakukan cleaning, penghapusan baris, perubahan nilai, maupun transformasi data. Pemeriksaan jumlah baris, jumlah kolom, dan missing value hanya dilakukan untuk memastikan kondisi awal dataset.

Hasil pemeriksaan awal terhadap data.csv menunjukkan:

- Jumlah baris: 4.424

- Jumlah kolom: 37

- Missing value: 0

- Variabel target: Target

- Kelas target: Dropout, Enrolled, Graduate

Hasil tersebut sesuai dengan karakteristik dataset yang telah dijelaskan pada dokumen proyek sebelumnya, yaitu 4.424 data mahasiswa dan target dengan tiga kelas.

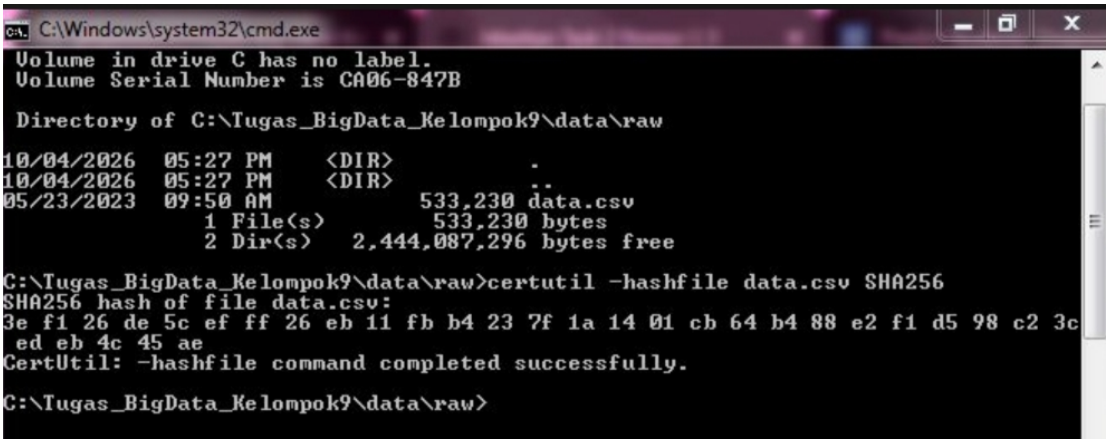
2.2. Pemeriksaan Awal Raw Data

Setelah file raw disimpan, saya melakukan pemeriksaan awal terhadap struktur dataset untuk memastikan bahwa file dapat dibaca dan memiliki struktur yang sesuai. Pemeriksaan dilakukan tanpa mengubah isi file.

Saat pertama kali membaca file, saya menemukan bahwa data menggunakan tanda titik koma (;) sebagai pemisah antar kolom. Oleh karena itu, pembacaan data dilakukan dengan menggunakan delimiter ;. Setelah delimiter disesuaikan, seluruh data terbaca menjadi 37 kolom dengan jumlah 4.424 baris.

Saya juga memeriksa keberadaan nilai kosong pada dataset. Berdasarkan pemeriksaan awal, tidak ditemukan nilai kosong pada data yang digunakan. Meskipun demikian, pemeriksaan ini belum dianggap sebagai proses cleaning karena belum dilakukan perubahan atau penghapusan terhadap data.

Pemeriksaan awal ini dilakukan agar saya mengetahui kondisi dasar dataset sebelum masuk ke tahapan pengolahan selanjutnya.



Gambar 3. Hasil Pemeriksaan Checksum

3. Pembuatan Data Dictionary

Setelah raw data berhasil diperoleh dan diperiksa, saya membuat data dictionary untuk mendokumentasikan struktur dan karakteristik setiap variabel yang terdapat dalam dataset.

Data dictionary digunakan untuk memberikan penjelasan mengenai fungsi setiap kolom sehingga variabel yang digunakan dalam analisis dapat dipahami dengan lebih mudah. Informasi yang dicantumkan meliputi nama variabel, tipe data, tipe konseptual, satuan, kategori atau nilai, peran sebagai target, key, grain, missing value, dan deskripsi variabel.

Data dictionary dibuat berdasarkan struktur aktual dari file data.csv. Berdasarkan hasil pemeriksaan, terdapat 37 variabel, yang terdiri dari 36 variabel prediktor dan satu variabel target.

Dalam menentukan tipe variabel, saya membedakan antara tipe data dan tipe konseptual. Tipe data menunjukkan bagaimana nilai disimpan di dalam file, sedangkan tipe konseptual menunjukkan karakter variabel dalam analisis. Sebagai contoh, variabel Gender disimpan dalam bentuk integer karena menggunakan kode angka, tetapi secara konseptual termasuk variabel kategorikal.

Untuk grain, saya menggunakan satu mahasiswa per baris, karena setiap baris pada dataset merepresentasikan satu mahasiswa. Hal tersebut juga sesuai dengan unit analisis pada proyek, yaitu mahasiswa secara individu.

Variabel Target ditetapkan sebagai variabel target karena berisi tiga kategori status akhir mahasiswa, yaitu Dropout, Enrolled, dan Graduate.

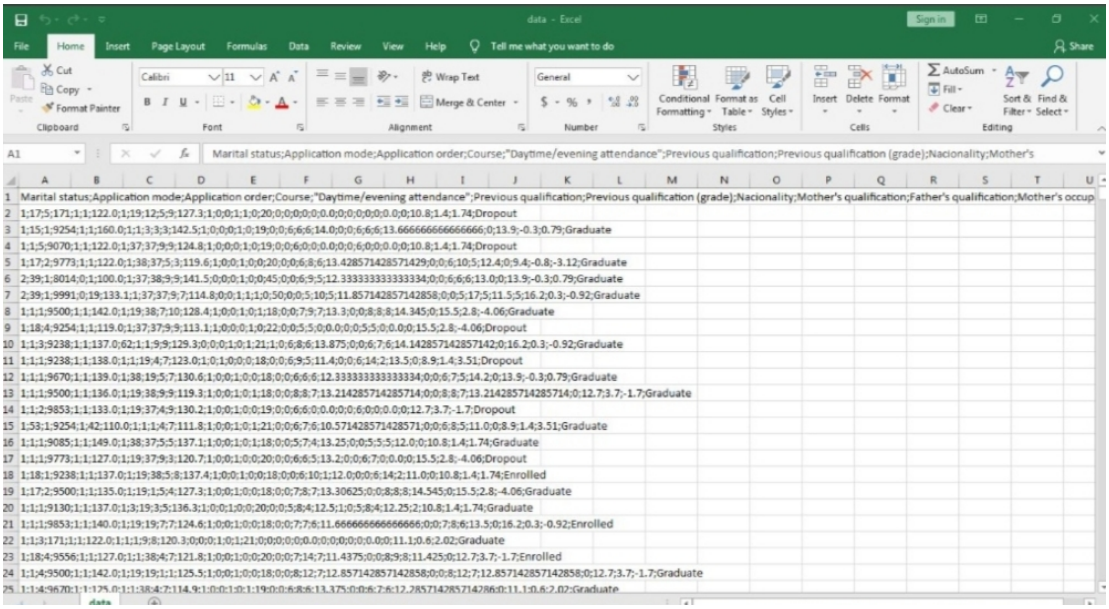
Hasil data dictionary kemudian disimpan dalam file:

```
tables
└── data_dictionary.xlsx
```

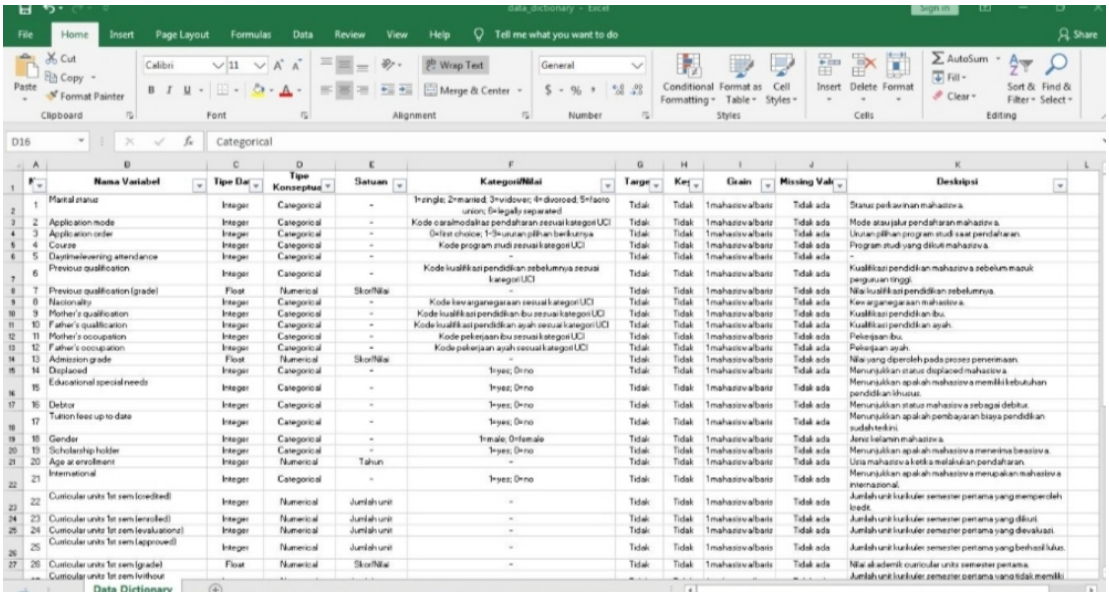
Struktur kolom Data Dictionary

Data dictionary yang dibuat memiliki kolom:

Kolom	**Fungsi**
No	Nomor urut variabel
Nama Variabel	Nama kolom pada dataset
Tipe Data	Bentuk penyimpanan data
Tipe Konseptual	Karakter variabel dalam analisis
Satuan	Satuan atau bentuk pengukuran
Kategori/Nilai	Nilai atau kategori yang digunakan
Target	Menunjukkan apakah variabel merupakan target
Key	Menunjukkan apakah variabel digunakan sebagai key
Grain	Tingkat unit data
Missing Value	Kondisi nilai kosong
Deskripsi	Penjelasan fungsi variabel



Gambar 3. Tampilan Awal Dataset



	Nama Variabel	Tipe Data	Tipe Konseptual	Satuan	Kategori/Nilai	Target	Key	Grain	Missing Value	Deskripsi
1	Marital status	Integer	Categorical	-	1=single; 2=married; 3=widower; 4= divorced; 5=facto union; 6=legally separated	Tidak	Tidak	1 mahasiswa/baris	Tidak ada	Status perkawinan mahasiswa.
2	Application mode	Integer	Categorical	-	Kode cara/modalitas pendaftaran sesuai kategori UCI	Tidak	Tidak	1 mahasiswa/baris	Tidak ada	Mode atau jalur pendaftaran mahasiswa.
3	Application order	Integer	Categorical	-	0=1st choice; 1-9=urutan pilihan berikutnya	Tidak	Tidak	1 mahasiswa/baris	Tidak ada	Urutan pilihan program studi saat pendaftaran.
4	Course	Integer	Categorical	-	Kode program studi sesuai kategori UCI	Tidak	Tidak	1 mahasiswa/baris	Tidak ada	Program studi yang diikuti mahasiswa.
5	Daytime/evening attendance	Integer	Categorical	-	-	Tidak	Tidak	1 mahasiswa/baris	Tidak ada	-
6	Previous qualification	Integer	Categorical	-	Kode kualifikasi pendidikan sebelumnya sesuai kategori UCI	Tidak	Tidak	1 mahasiswa/baris	Tidak ada	Kualifikasi pendidikan mahasiswa sebelum masuk perguruan tinggi.
7	Previous qualification (grade)	Float	Numerical	Skor/Nilai	-	Tidak	Tidak	1 mahasiswa/baris	Tidak ada	Nilai kualifikasi pendidikan sebelumnya.
8	Nationality	Integer	Categorical	-	Kode kewarganegaraan sesuai kategori UCI	Tidak	Tidak	1 mahasiswa/baris	Tidak ada	Kewarganegaraan mahasiswa.
9	Mother's qualification	Integer	Categorical	-	Kode kualifikasi pendidikan ibu sesuai kategori UCI	Tidak	Tidak	1 mahasiswa/baris	Tidak ada	Kualifikasi pendidikan ibu.
10	Father's qualification	Integer	Categorical	-	Kode kualifikasi pendidikan ayah sesuai kategori UCI	Tidak	Tidak	1 mahasiswa/baris	Tidak ada	Kualifikasi pendidikan ayah.
11	Mother's occupation	Integer	Categorical	-	Kode pekerjaan ibu sesuai kategori UCI	Tidak	Tidak	1 mahasiswa/baris	Tidak ada	Pekerjaan ibu.
12	Father's occupation	Integer	Categorical	-	Kode pekerjaan ayah sesuai kategori UCI	Tidak	Tidak	1 mahasiswa/baris	Tidak ada	Pekerjaan ayah.
13	Admission grade	Float	Numerical	Skor/Nilai	-	Tidak	Tidak	1 mahasiswa/baris	Tidak ada	Nilai yang diperoleh pada proses penerimaan.
14	Displaced	Integer	Categorical	-	1=yes; 0=no	Tidak	Tidak	1 mahasiswa/baris	Tidak ada	Menunjukkan status displaced mahasiswa.
15	Educational special needs	Integer	Categorical	-	1=yes; 0=no	Tidak	Tidak	1 mahasiswa/baris	Tidak ada	Menunjukkan apakah mahasiswa memiliki kebutuhan pendidikan khusus.
16	Debtor	Integer	Categorical	-	1=yes; 0=no	Tidak	Tidak	1 mahasiswa/baris	Tidak ada	Menunjukkan status mahasiswa sebagai debitur.
17	Tuition fees up to date	Integer	Categorical	-	1=yes; 0=no	Tidak	Tidak	1 mahasiswa/baris	Tidak ada	Menunjukkan apakah pembayaran biaya pendidikan sudah terkini.
18	Gender	Integer	Categorical	-	1=male; 0=female	Tidak	Tidak	1 mahasiswa/baris	Tidak ada	Jenis kelamin mahasiswa.
19	Scholarship holder	Integer	Categorical	-	1=yes; 0=no	Tidak	Tidak	1 mahasiswa/baris	Tidak ada	Menunjukkan apakah mahasiswa menerima beasiswa.
20	Age at enrollment	Integer	Numerical	Tahun	-	Tidak	Tidak	1 mahasiswa/baris	Tidak ada	Usia mahasiswa ketika melakukan pendaftaran.
21	International	Integer	Categorical	-	1=yes; 0=no	Tidak	Tidak	1 mahasiswa/baris	Tidak ada	Menunjukkan apakah mahasiswa merupakan mahasiswa internasional.
22	Curricular units 1st sem (credited)	Integer	Numerical	Jumlah unit	-	Tidak	Tidak	1 mahasiswa/baris	Tidak ada	Jumlah unit kurikuler semester pertama yang memperoleh kredit.
23	Curricular units 1st sem (enrolled)	Integer	Numerical	Jumlah unit	-	Tidak	Tidak	1 mahasiswa/baris	Tidak ada	Jumlah unit kurikuler semester pertama yang diikuti.
24	Curricular units 1st sem (evaluations)	Integer	Numerical	Jumlah unit	-	Tidak	Tidak	1 mahasiswa/baris	Tidak ada	Jumlah unit kurikuler semester pertama yang dievaluasi.
25	Curricular units 1st sem (approved)	Integer	Numerical	Jumlah unit	-	Tidak	Tidak	1 mahasiswa/baris	Tidak ada	Jumlah unit kurikuler semester pertama yang berhasil lulus.
26	Curricular units 1st sem (grade)	Float	Numerical	Skor/Nilai	-	Tidak	Tidak	1 mahasiswa/baris	Tidak ada	Nilai akademik curricular units semester pertama.
27	Curricular units 1st sem (without									Jumlah unit kurikuler semester pertama yang tidak memiliki

Gambar 4. Tampilan Data dictionary bagian lanjutan

4.1 Profiling Kualitas Data

Sebelum melanjutkan ke tahap penyiapan dan transformasi, profiling dilakukan pada data mentah yang disimpan di folder data /raw/ untuk mengevaluasi kondisi dan kualitas data. Profiling memeriksa nilai kosong (nilai yang tidak ada), data duplikat, pencilan (outlier), distribusi data, inkonsistensi nilai, distribusi label target, dan perubahan atau ketidaksesuaian struktur data.

Dataset yang digunakan terdiri dari 4.424 data siswa, yang terdiri dari 36 variabel prediktor dan satu variabel target, masing-masing dengan 37 kolom. Delimiter dataset adalah tanda titik koma (;). Menurut pemeriksaan awal, dataset tidak memiliki nilai yang hilang. Kondisi ini juga sesuai dengan hasil pemeriksaan yang dilakukan pada tahap penyimpanan data asli.

4.2 Pemeriksaan Missing Value

Untuk memastikan bahwa tidak ada nilai yang hilang pada seluruh kolom, pemeriksaan nilai hilang dilakukan untuk memastikan bahwa tidak ada nilai yang hilang yang dapat mengganggu proses analisis atau pemodelan. Hasil pemeriksaan menunjukkan bahwa seluruh 37 variabel tidak memiliki nilai yang hilang.

Oleh karena itu, metode imputasi seperti pengisian nilai median, rata-rata, atau modus tidak diperlukan. Nilai yang tersedia tetap dapat dilanjutkan ke tahap pemeriksaan berikutnya.

4.3 Pemeriksaan Data Duplikat

Selanjutnya, dipertimbangkan kemungkinan baris data yang sama secara keseluruhan. Tujuan dari pemeriksaan ini adalah untuk memastikan bahwa satu siswa tidak tercatat dalam dataset lebih dari satu kali. Setelah memeriksa dataset, kami menemukan bahwa tidak ada baris yang perlu dihapus sebagai duplikat. Akibatnya, semua data tetap ada untuk analisis selanjutnya.

4.4 Pemeriksaan Outlier

Variabel seperti jumlah mata kuliah yang diambil, jumlah mata kuliah yang lulus, dan nilai akademik pada semester pertama dan kedua adalah yang paling sering diuji untuk outlier.

Untuk pemeriksaan ini, metode statistik dan visualisasi seperti boxplot, minimum, maksimum, dan kuartil digunakan. Tujuannya bukan untuk menghapus nilai ekstrim secara langsung, tetapi untuk mengetahui apakah ada nilai yang berbeda dari pola umum data.

Nilai-nilai yang masih berada dalam rentang yang diizinkan oleh definisi variabel tidak langsung dihapus karena dapat menunjukkan kondisi mahasiswa yang sebenarnya. Oleh karena itu, hanya apabila ditemukan bahwa nilai tertentu tidak sah atau tidak sesuai dengan definisi variabel maka keputusan tentang penghapusan outlier dibuat.

4.5 Pemeriksaan Distribusi Data

Profiling distribusi dilakukan untuk mengidentifikasi karakteristik setiap variabel. Jumlah kemunculan variabel kategorikal menentukan pemeriksaan, sedangkan variabel numerik diperiksa dengan melihat nilai minimum, maksimum, rata-rata, median, dan standar deviasi. Pada Tugas 1 telah dijelaskan bahwa dataset memiliki tiga kelas target; Dropout, Enrolled, dan Graduate. Oleh karena itu, pemeriksaan distribusi sangat penting.

Selanjutnya, hasil distribusi target digunakan untuk menentukan apakah ada ketidakseimbangan kelas, atau ketidakseimbangan kelas. Hal ini penting karena hasil Tugas 1 menunjukkan bahwa lebih banyak siswa yang lulus daripada siswa yang keluar.

4.6 Pemeriksaan Inkonsistensi

Nilai setiap variabel dibandingkan dengan kategori atau rentang nilai yang diharapkan; pemeriksaan ini mencakup nilai kategori, kode numerik, dan kemungkinan adanya nilai di luar rentang yang telah ditentukan.

Dalam dataset, beberapa variabel kategorikal disimpan dalam bentuk kode numerik, sehingga nilainya tidak selalu dianggap sebagai data numerik secara konseptual. Sebagai contoh, variabel gender disimpan sebagai integer tetapi secara konseptual merupakan variabel kategorikal.

4.7 Pemeriksaan Label Target

Dalam analisis klasifikasi, label tujuan adalah variabel target, yang termasuk dalam tiga kategori: **Keluarnya Peserta yang Terdaftar** selama analisis, ketiga kategori tersebut digunakan sebagai kelas target. Selanjutnya, mereka akan berfungsi sebagai dasar untuk evaluasi model klasifikasi. Label diperiksa untuk memastikan bahwa kategori target tidak ditulis dengan salah, kosong, atau di luar tiga kelas yang telah ditentukan.

4.8 Pemeriksaan Perubahan Skema

Dataset memiliki struktur yang sama dengan data yang digunakan pada tahap sebelumnya. Hasil pemeriksaan menunjukkan bahwa dataset memiliki 37 kolom, yang terdiri dari 36 variabel prediktor dan satu variabel target. Tidak ada perubahan skema yang mengubah variabel utama atau fungsinya. Oleh karena itu, struktur dataset memungkinkan proses pembersihan dan transformasi.

5.1 Proses Cleaning

Hasil profiling menunjukkan bahwa dataset memiliki kondisi yang relatif baik karena tidak ditemukan nilai yang hilang. Oleh karena itu, proses perbaikan tidak dilakukan dengan menghapus baris atau imputasi nilai.

Proses membersihkan dilakukan dengan memastikan bahwa:

1. Tanda digunakan untuk membaca delimiter dataset
2. Nama kolom dan strukturnya dapat dibaca dengan benar
3. Tipe data untuk masing-masing variabel sesuai dengan atributnya
4. Nilai target hanya mencakup dropout, enrolled, dan grad
5. Pemeriksaan data duplikat
6. Nilai ekstrem dievaluasi
7. Data mentah tidak secara langsung diubah.

Hal ini mengikuti ketentuan yang menyatakan bahwa data mentah tidak boleh diubah secara manual dan semua perubahan dapat dilakukan kembali dengan kode.

5.2 Integrasi Data

Dalam penelitian ini, satu dataset utama dari Perpustakaan Pembelajaran Mesin UCI—Predicting Students' Dropout and Academic Success—digunakan untuk analisis. Oleh karena itu, tidak ada penggabungan dataset eksternal dilakukan. Data utama penelitian berasal dari dataset ini. Oleh karena itu, tahap integrasi berkonsentrasi pada membuat struktur data siap sehingga seluruh variabel dapat digunakan secara konsisten selama proses analisis dan pemodelan.

5.3 Transformasi Data

Proses transformasi dilakukan untuk menyesuaikan data untuk memenuhi persyaratan analisis statistik dan pembelajaran mesin. Untuk membedakan variabel berdasarkan kategori konseptualnya adalah hal yang sangat penting.

Variabel kategorikal tidak dianggap sebagai variabel numerik kontinu ketika disimpan dalam kode angka. Sementara itu, variabel yang menunjukkan jumlah atau nilai akademik dapat digunakan sebagai variabel numerik. Dengan tiga kelas; Dropout, Enrolled, dan Graduate, variabel Target digunakan sebagai label klasifikasi.

Hasil proses cleaning dan transformasi kemudian disimpan pada folder:



Gambar 5. Susunan Folder

Struktur ini membedakan data asli dari data yang telah diproses, sehingga data asli tetap dapat digunakan sebagai sumber acuan.

5.4 Catatan Cleaning

Karena dataset sudah memiliki kualitas yang cukup baik, proses membersihkannya tidak memerlukan perubahan yang signifikan. Pemeriksaan, validasi struktur, pengecekan nilai yang hilang, duplikasi, distribusi, outlier, dan validasi label adalah proses utama yang dilakukan. Metode ini dapat mempertahankan karakteristik dataset asli dengan mengurangi perubahan data.

6.1 Tujuan EDA

Proses analisis data eksploratif dilakukan untuk memahami karakteristik dataset dan menemukan pola hubungan antara status akademik, sosial-ekonomi, dan demografi mahasiswa dengan pendidikan mereka.

EDA berbicara tentang pertanyaan analitik yang telah ditentukan seperti mengetahui faktor non-akademik yang berhubungan dengan dropout, mengetahui sejauh mana prestasi akademik semester awal dapat digunakan untuk memprediksi status siswa, dan mengevaluasi kemampuan algoritma klasifikasi untuk mengatasi ketidakseimbangan kelas.

6.2 Statistik Deskriptif

Untuk mengetahui karakteristik umum dari data, variabel numerik dilakukan analisis statistik deskriptif. Statistik yang digunakan meliputi; jumlah data, nilai rata-rata, nilai median, standar deviasi, nilai minimum, nilai kuartil, dan nilai maksimum. Statistik deskriptif digunakan untuk mendapatkan gambaran umum tentang kondisi akademik siswa. Mereka juga membantu menemukan pola yang berbeda dalam nilai.

6.3 Distribusi Status Mahasiswa

Variabel Target adalah subjek analisis pertama. Jumlah siswa yang termasuk dalam kategori Dropout, Enrolled, dan Graduate dihitung dengan kontribusi ini. Bar chart digunakan sebagai visualisasi.

Penafsiran yang diharapkan:

Visualisasi menampilkan perbandingan jumlah siswa berdasarkan status akhir mereka. Dalam tahap pemodelan, ketidakseimbangan kelas harus diperhatikan jika jumlah kategori graduan lebih besar daripada kategori dropout.

6.4 Hubungan Faktor Akademik dengan Target

Selanjutnya, perbandingan prestasi akademik siswa dilakukan berdasarkan status Dropout, Enrolled, dan Graduate.

Ada beberapa variabel yang dapat dievaluasi, antara lain:

1. Jumlah mata kuliah yang diambil dan lulus di semester pertama nilai akademik semester pertama.
2. Jumlah mata kuliah yang diambil dan lulus di semester kedua.
3. Dan nilai akademik semester kedua.

Tujuan dari analisis ini adalah untuk mengetahui apakah siswa yang memiliki prestasi akademik yang lebih rendah memiliki kecenderungan lebih besar untuk masuk dalam kategori siswa yang meninggalkan sekolah. Berdasarkan rata-rata masing-masing kelompok, boxplot atau barplot dapat digunakan sebagai visualisasi.

6.5 Hubungan Faktor Demografi dan Sosial-Ekonomi

Selain itu, EDA dilakukan terhadap faktor sosial-ekonomi dan demografi. Berikut ini adalah beberapa variabel yang relevan dengan penelitian:

1. Gender
2. Status pernikahan
3. Pendidikan orang tua
4. Pekerjaan orang tua
5. Status beasiswa
6. Utang biaya kuliah
7. Keadaan keuangan saat pendaftaran

Analisis dilakukan dengan membandingkan rasio keluar, terdaftar, dan lulus dalam setiap kategori. Sehingga perbedaan proporsi antar kategori lebih mudah diamati, visualisasi yang digunakan dapat berupa bar chart yang disusun. Metode ini sesuai dengan rancangan yang menyebutkan penggunaan bar stacked untuk menghitung rasio kelulusan dan keluar program studi.

6.6 Analisis Korelasi

Analisis korelasi dilakukan untuk mengetahui bagaimana variabel numerik berhubungan satu sama lain. Hasilnya dapat divisualisasikan dengan menggunakan peta panas korelasi. Variabel yang memiliki korelasi relatif kuat dengan variabel numerik lainnya dapat dilihat melalui heatmap. Ini juga membantu menemukan pola korelasi antar fitur. Heatmap yang dimaksudkan untuk menjadi salah satu visualisasi utama EDA.

6.7 Ringkasan Hasil EDA

Analisis difokuskan pada tiga fokus penelitian utama berdasarkan tahapan EDA yang dilakukan; faktor-faktor non-akademik seperti status keuangan, utang, beasiswa, dan latar belakang keluarga dievaluasi berdasarkan status akhir mahasiswa.

Untuk mengetahui pola yang membedakan siswa yang keluar, terdaftar, dan lulus, prestasi akademik semester pertama dan kedua dievaluasi. Dalam proses klasifikasi, distribusi target diperiksa untuk menentukan tingkat ketidakseimbangan kelas.

Tahap pemodelan pembelajaran mesin didasarkan pada temuan EDA. Kelompok merencanakan Logistic Regression sebagai dasar dan Random Forest sebagai model tambahan. F1-Score dan Recall, terutama recall kelas Dropout, dianggap sebagai metrik penting karena ketidakseimbangan kelas.

DAFTAR PUSTAKA

Realinho, V., Machado, J., Baptista, L., & Martins, M. V. (2021). Predict Students' Dropout and Academic Success [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C5MC89.

Lee, J. Y., & Lee, S. (2023). A study on dropout prediction for university students using machine learning techniques. *Applied Sciences, 13*(21), 12004. https://doi.org/10.3390/app132112004.

Chung, J., & Lee, J. (2023). University student dropout prediction using pretrained language models. *Applied Sciences, 13*(12), 7073. https://doi.org/10.3390/app13127073.

Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.