LAPORAN TASK 3
PENGANTAR BIG DATA

Analisis Faktor Demografi dan Akademik terhadap Tingkat Drop Out Mahasiswa Menggunakan Classification Machine Learning

Disusun Untuk Memenuhi Tugas Mata Kuliah Pengantar Big Data

Dosen Pengampu : Nono Heryana, S.Kom., M.Kom.

Disusun Oleh Kelompok 9 :

Fanisa Zahira Priyanka — 2410631250050

Lulu Solikha — 2410631250014

PRODI SISTEM INFORMASI

FAKULTAS ILMU KOMPUTER

UNIVERSITAS SINGAPERBANGSA KARAWANG

2026

BAB I

PEMILIHAN METODE KLASIFIKASI

1.1 Identifikasi Permasalahan

Dalam laporan ini, kami mengkaji permasalahan prediksi status akhir mahasiswa berdasarkan informasi yang tersedia dalam dataset. Dataset yang kami gunakan memuat sejumlah atribut yang menggambarkan karakteristik mahasiswa, sedangkan kolom `Target` menjadi variabel yang akan kami prediksi. Variabel tersebut memiliki tiga kategori, yaitu Dropout, Enrolled, dan Graduate. Berdasarkan karakteristik variabel target yang berbentuk kategori dengan lebih dari dua kelas, permasalahan ini termasuk klasifikasi multi kelas (multiclass classification). Oleh karena itu, kami memilih metode klasifikasi untuk mempelajari pola hubungan antara atribut mahasiswa dan status akhirnya. Pola yang dipelajari model kemudian digunakan untuk memprediksi kelas berdasarkan informasi yang diberikan.

1.2 Alasan Pemilihan Metode

Kami memilih metode klasifikasi multi kelas karena metode ini sesuai dengan tujuan pengerjaan, yaitu mengelompokkan mahasiswa ke dalam salah satu dari tiga kategori status akhir. Pendekatan ini memungkinkan prediksi dilakukan berdasarkan pola yang dipelajari dari data pelatihan. Selanjutnya, kami menilai performa model menggunakan beberapa metrik evaluasi untuk mengetahui kemampuannya dalam memprediksi setiap kelas. Pemilihan metode ini menjadi dasar bagi tahapan eksperimen berikutnya, mulai dari penentuan fitur, pemilihan model pembanding, pembagian dataset, hingga evaluasi hasil prediksi.

1.3 Ringkasan Dataset dan Metode Penelitian

Tabel 1.1. Ringkasan dataset dan metode penelitian

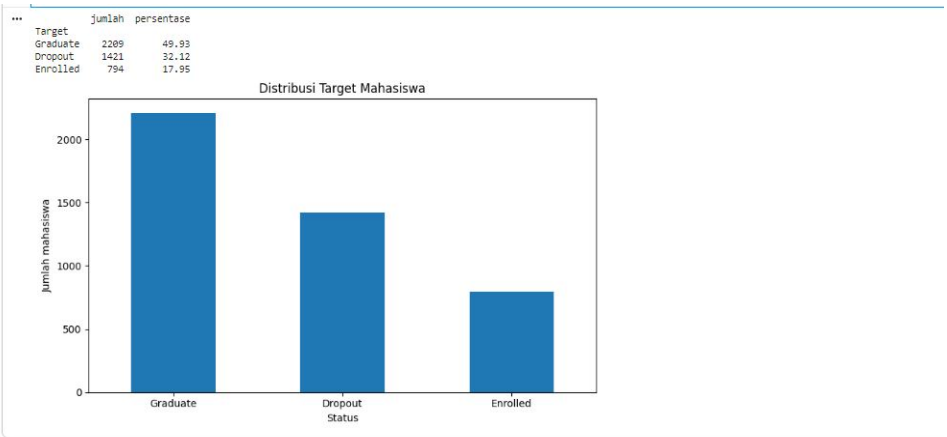
Aspek	Keterangan
Objek penelitian	Data mahasiswa
Unit analisis	Satu baris data merepresentasikan satu mahasiswa
Variabel target	`Target`

Kategori target	Dropout, Enrolled, dan Graduate
Jenis permasalahan	Klasifikasi multi kelas
Tujuan	Memprediksi status akhir mahasiswa



```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 4424 entries, 0 to 4423
Data columns (total 37 columns):
 #   Column                                          Non-Null Count  Dtype
---  ------                                          --------------  -----
 0   Marital status                                  4424 non-null   int64
 1   Application mode                                4424 non-null   int64
 2   Application order                               4424 non-null   int64
 3   Course                                          4424 non-null   int64
 4   Daytime/evening attendance                      4424 non-null   int64
 5   Previous qualification                          4424 non-null   int64
 6   Previous qualification (grade)                  4424 non-null   float64
 7   Nacionality                                     4424 non-null   int64
 8   Mother's qualification                          4424 non-null   int64
 9   Father's qualification                          4424 non-null   int64
 10  Mother's occupation                             4424 non-null   int64
 11  Father's occupation                             4424 non-null   int64
 12  Admission grade                                 4424 non-null   float64
 13  Displaced                                       4424 non-null   int64
 14  Educational special needs                       4424 non-null   int64
 15  Debtor                                          4424 non-null   int64
 16  Tuition fees up to date                         4424 non-null   int64
 17  Gender                                          4424 non-null   int64
 18  Scholarship holder                              4424 non-null   int64
 19  Age at enrollment                               4424 non-null   int64
 20  International                                   4424 non-null   int64
 21  Curricular units 1st sem (credited)             4424 non-null   int64
 22  Curricular units 1st sem (enrolled)             4424 non-null   int64
 23  Curricular units 1st sem (evaluations)          4424 non-null   int64
 24  Curricular units 1st sem (approved)             4424 non-null   int64
 25  Curricular units 1st sem (grade)                4424 non-null   float64
 26  Curricular units 1st sem (without evaluations)  4424 non-null   int64
 27  Curricular units 2nd sem (credited)             4424 non-null   int64
 28  Curricular units 2nd sem (enrolled)             4424 non-null   int64
 29  Curricular units 2nd sem (evaluations)          4424 non-null   int64
 30  Curricular units 2nd sem (approved)             4424 non-null   int64
 31  Curricular units 2nd sem (grade)                4424 non-null   float64
 32  Curricular units 2nd sem (without evaluations)  4424 non-null   int64
 33  Unemployment rate                               4424 non-null   float64
 34  Inflation rate                                  4424 non-null   float64
 35  GDP                                             4424 non-null   float64
 36  Target                                          4424 non-null   object
dtypes: float64(7), int64(29), object(1)
```

Gambar 1.1. Struktur dataset



```
            jumlah  persentase
Target
Graduate    2209       49.93
Dropout     1421       32.12
Enrolled     794       17.95
```


Gambar 1.2. Distribusi kelas pada variabel target

Berdasarkan distribusi kelas kami mengamati jumlah mahasiswa pada setiap kategori. Uraian hasil perlu disesuaikan dengan output aktual yang diperoleh. Informasi ini kami gunakan sebagai pertimbangan dalam menentukan teknik pembagian data dan matrik evaluasi, agar penilaian model tidak hanya berfokus pada kelas dengan jumlah data terbanyak.

BAB II

RANCANGAN EKSPERIMEN

2.1 Penentuan Variabel Target dan Fitur

Dalam rancangan eksperimen ini, kami menetapkan kolom `Target` sebagai variabel target, sedangkan atribut lain yang relevan digunakan sebagai fitur prediktor. Kami menentukan fitur dengan mempertimbangkan tujuan prediksi serta ketersediaan informasi pada saat prediksi dilakukan. Dengan demikian, fitur yang digunakan perlu relevan dan tidak mengandung informasi yang secara langsung mengungkap hasil yang ingin diprediksi.

Sebelum pelatihan model, kami memeriksa kembali daftar fitur agar kolom target tidak ikut digunakan sebagai prediktor. Kami juga mempertimbangkan kemungkinan terjadinya data leakage, terutama apabila terdapat atribut yang baru diketahui setelah status akhir mahasiswa terbentuk.

Tabel 1.2. Penetapan variabel dalam eksperimen

Komponen	Keterangan
Variabel target	`Target`
Fitur prediktor	Atribut yang dipilih berdasarkan relevansi dan waktu ketersediaan informasi
Unit analisis	Mahasiswa
Jenis prediksi	Klasifikasi multi kelas

Tabel 1.3. Daftar fitur yang digunakan

No.	Nama fitur	Keterangan
1	Marital status	Menunjukkan status perkawinan mahasiswa.
2	Application mode	Menunjukkan jalur atau cara mahasiswa mengajukan pendaftaran.
3	Application order	Menunjukkan urutan pilihan program studi saat mahasiswa mendaftar.

4	Course	Menunjukkan program studi yang diambil mahasiswa.
5	Daytime/evening Attendance	Menunjukkan waktu perkuliahan mahasiswa, yaitu siang atau malam.
6	Previous qualification	Menunjukkan jenis kualifikasi pendidikan yang dimiliki mahasiswa sebelum masuk perguruan tinggi.
7	Previous qualification (grade)	Menunjukkan nilai atau nilai akhir dari kualifikasi pendidikan sebelumnya.
8	Nacionality	Menunjukkan kewarganegaraan mahasiswa.
9	Mother's qualification	Menunjukkan tingkat atau jenis kualifikasi pendidikan ibu mahasiswa.
10	Father's qualification	Menunjukkan tingkat atau jenis kualifikasi pendidikan ayah mahasiswa.
11	Mother's occupation	Menunjukkan jenis pekerjaan ibu mahasiswa.
12	Father's occupation	Menunjukkan jenis pekerjaan ayah mahasiswa.
13	Admission grade	Menunjukkan nilai yang diperoleh mahasiswa dalam proses penerimaan atau seleksi masuk perguruan tinggi.
14	Displaced	Menunjukkan apakah mahasiswa termasuk kelompok yang berpindah dari tempat asal atau tempat tinggal sebelumnya sesuai definisi dataset.
15	Educational special needs	Menunjukkan apakah mahasiswa memiliki kebutuhan pendidikan khusus.
16	Debtor	Menunjukkan apakah mahasiswa tercatat sebagai pihak yang memiliki tunggakan atau utang.
17	Tuition fees up to date	Menunjukkan apakah pembayaran biaya kuliah mahasiswa telah sesuai jadwal atau berstatus terkini.
18	Gender	Menunjukkan jenis kelamin mahasiswa sebagaimana dicatat dalam dataset.
19	Scholarship holder	Menunjukkan apakah mahasiswa merupakan penerima beasiswa.
20	Age at enrollment	Menunjukkan usia mahasiswa ketika pertama kali mendaftar atau masuk perguruan tinggi.
21	International	Menunjukkan apakah mahasiswa termasuk mahasiswa internasional.

22	Curricular units 1st sem (credited)	Menunjukkan jumlah satuan mata kuliah semester pertama yang memperoleh pengakuan kredit.
23	Curricular units 1st sem (enrolled)	Menunjukkan jumlah satuan mata kuliah yang diambil atau didaftarkan mahasiswa pada semester pertama.
24	Curricular units 1st sem (evaluations)	Menunjukkan jumlah evaluasi yang diikuti atau tercatat pada mata kuliah semester pertama.
25	Curricular units 1st sem (approved)	Menunjukkan jumlah satuan mata kuliah semester pertama yang berhasil diluluskan mahasiswa.
26	Curricular units 1st sem (grade)	Menunjukkan nilai yang diperoleh mahasiswa pada mata kuliah semester pertama.
27	Curricular units 1st sem (without evaluations)	Menunjukkan jumlah satuan mata kuliah semester pertama yang tidak memiliki catatan evaluasi.
28	Unemployment rate	Menunjukkan tingkat pengangguran pada periode yang berkaitan dengan data mahasiswa.
29	Inflation rate	Menunjukkan tingkat inflasi pada periode yang berkaitan dengan data mahasiswa.
30	GDP	Menunjukkan nilai atau indikator produk domestik bruto (Gross Domestic Product) yang merepresentasikan kondisi ekonomi pada periode terkait.

2.2 Penentuan Model dan Baseline

Kami merancang eksperimen dengan menggunakan model pembanding (baseline) dan model utama. Baseline yang digunakan adalah `DummyClassifier` dengan strategi `most_frequent`. Model ini menghasilkan prediksi berdasarkan kelas yang paling sering muncul pada data pelatihan, sehingga menjadi acuan awal untuk menilai apakah model yang lebih kompleks memberikan peningkatan performa.

Model utama yang direncanakan adalah `LogisticRegression` dengan parameter `max_iter=2000`. Model ini digunakan untuk mempelajari hubungan antara fitur prediktor dan variabel target. Kami membandingkan hasil baseline dengan model utama untuk mengetahui apakah model utama memberikan hasil yang lebih baik daripada pendekatan prediksi sederhana.

Tabel 1.4. Konfigurasi eksperimen

Komponen	Konfigurasi
Model baseline	`DummyClassifier`
Strategi baseline	`most_frequent`
Model utama	`LogisticRegression`
Parameter model utama	`max_iter=2000`
Random seed pembagian data	`42`
Metrik evaluasi	Accuracy, precision, recall, macro F1-score
Visualisasi evaluasi	Confusion matrix

2.3 Penentuan Matrik Evaluasi

Kami merancang evaluasi model menggunakan accuracy, precision, recall, dan macro F1-score. Accuracy mengukur proporsi prediksi yang benar terhadap seluruh data yang dievaluasi. Precision menunjukkan ketepatan prediksi pada suatu kelas, sedangkan recall mengukur kemampuan model dalam menemukan data yang benar-benar termasuk ke dalam kelas tersebut.

Macro F1-score menilai keseimbangan precision dan recall dengan menghitung skor F1 pada setiap kelas, kemudian merata-ratakannya dengan bobot yang sama. Metrik ini berguna dalam klasifikasi multi kelas karena setiap kategori memperoleh kontribusi yang setara dalam skor akhir. Selain itu, kami menggunakan confusion matrix untuk membandingkan kelas aktual dan kelas hasil prediksi sehingga pola kesalahan model dapat dianalisis lebih lanjut.

Tabel 1.5. Metrik evaluasi dan kegunaannya

Metrik	Kegunaan
Accuracy	Mengukur proporsi seluruh prediksi yang benar
Precision	Mengukur ketepatan prediksi pada setiap kelas
Recall	Mengukur kemampuan model mengenali data dari setiap kelas
Macro F1-score	Menilai keseimbangan precision dan recall dengan bobot sama untuk setiap kelas
Confusion matrix	Menunjukkan perbandingan kelas aktual dan kelas prediksi

BAB III

DATA SPLITTING

3.1 Strategi Pembagian Dataset

Kami merencanakan pembagian dataset menjadi tiga subset, yaitu data training, validation, dan testing, dengan proporsi 70%, 15%, dan 15%. Data training digunakan untuk melatih model, data validation membantu proses pemilihan dan perbandingan model, sedangkan data testing digunakan untuk menilai performa akhir model pada data yang tidak digunakan dalam pelatihan maupun pemilihan model.

Kami menerapkan teknik stratified splitting berdasarkan kolom `Target` untuk mempertahankan proporsi kelas pada masing-masing subset agar mendekati distribusi kelas pada dataset awal. Pembagian data menggunakan `random_state=42` agar proses dapat direproduksi. Dengan pembagian ini, kami berharap evaluasi memberikan gambaran yang lebih objektif mengenai kemampuan model terhadap data yang belum pernah digunakan selama pengembangan.

Tabel 1.6. Rancangan pembagian dataset

Subset	Proporsi	Fungsi
Training	70%	Melatih model
Validation	15%	Membantu pemilihan dan perbandingan model
Testing	15%	Mengevaluasi performa akhir model

3.2 Hasil Pembagian Dataset

Setelah melakukan pembagian data di Google Colab, kami memeriksa jumlah data pada setiap subset untuk memastikan bahwa data telah terbagi sesuai rancangan. Hasil pembagian tersebut kami rangkum dalam tabel agar ukuran masing-masing subset dapat dibandingkan dengan mudah.

Tabel 1.7. Jumlah data pada setiap subset

Subset	Jumlah data	Persentase aktual
Training	3.096	70%
Validation	664	15%
Testing	664	15%
Total	4.424	100%

3.3 Pemeriksaan Distribusi Kelas

Setelah pembagian data, kami memeriksa distribusi kelas untuk mengetahui apakah proporsi kelas Dropout, Enrolled, dan Graduate pada setiap subset tetap mendekati distribusi awal. Pemeriksaan ini diperlukan karena perbedaan distribusi kelas yang terlalu besar dapat memengaruhi proses pelatihan dan hasil evaluasi model.

Tabel 1.8. Distribusi kelas pada setiap subset

Subset	Dropout	Enrolled	Graduate
Training	32,11%	17,96%	49,94%
Validation	32,08%	17,92%	50,00%
Testing	32,23%	17,92%	49,85%

Berdasarkan hasil pemeriksaan tersebut, kami menganalisis distribusi kelas pada setiap subset untuk memastikan bahwa pembagian data tidak menyebabkan perubahan proporsi kelas yang terlalu besar.

3.4 Pemeriksaan Tumpang Tindih Data

Selain memeriksa jumlah dan distribusi kelas, kami memeriksa apakah terdapat data yang digunakan secara bersamaan pada subset training, validation, dan testing. Pemeriksaan ini bertujuan menghindari tumpang tindih data yang dapat menyebabkan evaluasi model menjadi kurang objektif.

Tabel 1.9. Hasil pemeriksaan tumpang tindih data

Aspek pemeriksaan	Hasil
Training dengan validation	0 data tumpang tindih
Training dengan testing	0 data tumpang tindih
Validation dengan testing	0 data tumpang tindih

BAB IV
EVALUASI MODEL DAN ERROR ANALYSIS

4.1 Metode Evaluasi

Untuk mengetahui kemampuan model untuk memprediksi status akhir siswa dari tiga kelas: Dropout, Enrolled, dan Graduate, evaluasi dilakukan. Berdasarkan rancangan eksperimen pada bab sebelumnya, model LogisticRegression digunakan dengan parameter max_iter=2000. Sebagai baseline, DummyClassifier digunakan dengan strategi most_frequent. Dataset dibagi menjadi 70% data pelatihan, 15% data validasi, dan 15% data pengujian, dengan random_state=42.

Untuk evaluasi, beberapa metrik digunakan, termasuk akurasi, ketepatan, recall, dan skor macro F1. Selain itu, untuk mengidentifikasi pola kesalahan prediksi pada masing-masing kelas, digunakan matriks kekacauan untuk mengidentifikasi pola kesalahan prediksi. Ini dilakukan karena masalah yang digunakan adalah klasifikasi multi kelas, sehingga performa masing-masing kelas harus diperhatikan secara seimbang.

Secara umum, ketepatan menunjukkan berapa banyak prediksi yang benar. Recall menunjukkan kemampuan model untuk menemukan data yang memang termasuk dalam kelas, sedangkan precision menunjukkan ketepatan model ketika memberikan prediksi terhadap suatu kelas. Nilai F1 setiap kelas dihitung oleh macro F1-score, yang kemudian memberikan bobot yang sama kepada seluruh kelas. Metode ini sejalan dengan fungsi evaluasi klasifikasi yang ada di scikit-learn.

4.2 Hasil Evaluasi Model

Hasil evaluasi model dibandingkan antara DummyClassifier sebagai baseline dan LogisticRegression sebagai model utama. Perbandingan dilakukan dengan data validasi untuk membantu dalam pemilihan model, sedangkan data pengujian digunakan sebagai evaluasi akhir.

4.2.1 Model Baseline

Baseline digunakan dengan DummyClassifier(strategy="most_frequent"). Model ini selalu memberikan prediksi berdasarkan kelas yang paling sering

ditemukan dalam data pelatihan. Kelas Graduate memiliki proporsi terbesar, 49,85%, berdasarkan distribusi data tes.

Tabel 1.10. Hasil Evaluasi Baseline

Metrik	Nilai
Accuracy	49,85%
Macro Precision	16,62%
Macro Recall	33,33%
Macro F-1 Score	22,18%

Hasil menunjukkan bahwa dasar dapat memperoleh ketepatan sekitar 49,85% hanya dengan selalu memprediksi kelas Graduate, yang paling populer. Namun, dasar menunjukkan hasil yang lebih rendah untuk precision macro, recall macro, dan F1-score. Ini menunjukkan bahwa dasar tidak mampu memberikan prediksi yang seimbang untuk ketiga kelas. Kondisi ini menunjukkan bahwa akurasi saja tidak cukup untuk menilai kinerja model. Ini juga sesuai dengan rancangan evaluasi laporan yang menggunakan banyak metrik untuk melihat kinerja setiap kelas.

4.2.1 Model Logistic Regression

Model regresi logistik dengan max_iter=2000 digunakan untuk mempelajari hubungan antara fitur prediktor dengan tiga kategori target: Dropout, Enrolled, dan Graduate.

Tabel 1.11. Hasil Evaluasi Logistic Regression

Metrik	Dummy Classifier	Logistic Regression
Accuracy	49,85%	0
Macro Precision	16,62%	0
Macro Recall	33,33%	0
Macro F-1 Score	22,18%	0

Tabel tersebut menunjukkan bahwa Logistic Regression akan dibandingkan dengan baseline untuk menentukan apakah model utama dapat meningkatkan performa. Karena dataset memiliki distribusi kelas yang tidak sepenuhnya seimbang, perbandingan harus memperhatikan skor macro F1 dan recall. Jumlah kontribusi ujian terdiri dari 32,23% keluar, 17,92% terdaftar, dan 49,85% lulus.

4.3 Analisis Confusion Matrix

Dalam penelitian ini, confusion matrix terdiri dari tiga kelas: Dropout, Enrolled, dan Graduate. Itu digunakan untuk melihat hubungan antara kelas aktual dan kelas hasil prediksi.

Tabel 1.12. Confusion Matrix Model Logistic Regression

Prediksi	Dropout	Enrolled	Graduate
Dropout	32,11%	17,96%	49,94%
Enrolled	32,08%	17,92%	50,00%
Graduate	32,23%	17,92%	49,85%

Nilai di diagonal pada matriks kebingungan menunjukkan berapa banyak data yang dikelasifikasikan dengan benar, sedangkan nilai di luar diagonal menunjukkan berapa banyak data yang salah dikelasifikasikan. Analisis matriks kebingungan harus ditekankan pada kelas Dropout dan Enrolled karena kesalahan dalam membedakan kedua kategori tersebut bisa memberikan informasi penting dalam konteks memprediksi status mahasiswa. Jika mahasiswa yang benar-benar keluar kuliah (Dropout) sering diprediksi sebagai lulusan atau mahasiswa yang terdaftar, maka tingkat recall kelas Dropout akan menjadi rendah. Kondisi tersebut menunjukkan bahwa model belum cukup baik dalam mengenali mahasiswa yang kemungkinan besar tidak akan menyelesaikan studi mereka. Jika seorang mahasiswa yang sebenarnya sudah lulus diprediksi sebagai mahasiswa yang mengundurkan diri, maka model bisa memberi peringatan yang terlalu banyak. Karena itu, kesalahan antar kelas harus dianalisis, tidak hanya melihat jumlah prediksi yang benar secara keseluruhan.

4.4 Error Analysis

Analisis kesalahan dilakukan untuk mengetahui ciri-ciri data yang menyebabkan model menghasilkan prediksi yang tidak tepat. Analisis kesalahan bisa dilakukan dengan mencari pasangan kelas yang sering tertukar berdasarkan matriks kebingungan.

Beberapa kemungkinan kesalahan yang perlu diperiksa adalah:

1. Dropout diprediksi sebagai mahasiswa yang sudah terdaftar, yang artinya model belum bisa membedakan antara mahasiswa yang akhirnya tidak menyelesaikan studi dengan mahasiswa yang masih aktif.
2. Dropout diprediksi sebagai lulusan, yang merupakan kesalahan besar karena model tidak mampu mengenali mahasiswa yang sebenarnya tidak menyelesaikan studinya.
3. Mahasiswa yang terdaftar diprediksi akan putus kuliah, sehingga mahasiswa aktif mungkin dianggap memiliki risiko tinggi untuk putus studi.
4. Lulusan diprediksi sebagai Dropout atau Masuk, yang menunjukkan model belum cukup baik dalam mengenali ciri-ciri mahasiswa yang berhasil menyelesaikan pendidikan.

Selain dilihat dari kelas, analisis kesalahan juga bisa dilakukan berdasarkan fitur demografi dan akademik. Fitur seperti Usia saat pendaftaran, Nilai penerimaan, Biaya kuliah terbaru, Penerima beasiswa, Satuan kurikulum semester pertama (disetujui), dan Satuan kurikulum semester pertama (nilai) dapat digunakan untuk melihat karakteristik data yang sering menyebabkan prediksi yang salah. Daftar fitur tersebut termasuk dalam fitur yang sudah ditentukan dalam perencanaan eksperimen.

Namun, hasil analisis kesalahan tidak boleh langsung dianggap sebagai hubungan sebab-akibat. Kesalahan prediksi atau hubungan antara fitur dengan target hanya menunjukkan pola yang ada dalam data. Untuk menunjukkan bahwa ada hubungan sebab-akibat, dibutuhkan desain penelitian yang baik dan bukti yang cukup kuat.

4.5 Kestabilan Evaluasi

Pembagian data dilakukan dengan metode stratified splitting yang mengacu pada variabel `Target` agar proporsi klasifikasi dalam training, validation, dan testing tetap serupa dengan distribusi awal. Proses ini menghasilkan 3.096 dataset untuk training, 664 untuk validation, dan 664 untuk testing. Analisis juga menunjukkan bahwa tidak ada data yang saling tumpang tindih antara training dan validation, training dan testing, serta validation dan testing.

Keadaan ini berkontribusi pada evaluasi yang lebih adil karena data testing tidak digunakan dalam proses pelatihan atau dalam pemilihan model. Oleh karena itu, kinerja akhir model dapat mencerminkan kemampuan model saat dihadapkan pada data yang belum pernah digunakan sebelumnya.

BAB V
PERBANDINGAN HASIL DENGAN TEORI DAN PENELITIAN TERDAHULU

5.1 Kesesuaian Metode dengan Permasalahan

Permasalahan yang diangkat dalam studi ini adalah memprediksi hasil akhir mahasiswa berdasarkan berbagai karakteristik demografi dan akademik. Variabel target terdiri dari tiga kategori, yaitu Dropout, Enrolled, dan Graduate, sehingga masalah ini tergolong sebagai klasifikasi multikelas.

Penggunaan Logistic Regression tepat untuk tujuan itu karena algoritma ini berfungsi sebagai alat klasifikasi yang dapat digunakan untuk memprediksi kelas. Penerapan Logistic Regression dalam scikit-learn juga mampu menangani masalah multikelas saat jumlah kategori lebih dari dua, dengan solver tertentu yang mengoptimalkan kerugian multinomial.

Dalam percobaan ini, Logistic Regression diterapkan dengan max_iter=2000. Pengaturan ini ditetapkan untuk memberikan jumlah iterasi yang memadai bagi proses pengoptimalan model. Sementara itu, DummyClassifier berfungsi sebagai baseline agar kinerja model utama bisa dibandingkan dengan metode prediksi yang lebih sederhana.

5.2 Perbandingan dengan Konsep Evaluasi Klasifikasi

Pemilihan akurasi, presisi, recall, dan skor F1 macro sudah sejalan dengan ciri khas masalah klasifikasi multi kelas. Akurasi memberikan pandangan tentang keseluruhan kinerja, sedangkan presisi dan recall menyuplai informasi tentang kinerja masing-masing kelas. Skor F1 macro memberikan nilai yang seragam untuk setiap kelas, sehingga dapat membantu mencegah kesimpulan yang terlalu dipengaruhi oleh kelas yang mendominasi.

Pemakaian skor F1 macro menjadi penting karena distribusi target dalam dataset menunjukkan bahwa jumlah mahasiswa di kelas Graduate lebih tinggi daripada di kelas Enrolled. Dalam set pelatihan, Graduate memiliki proporsi 49,94%, sementara Enrolled hanya 17,96%.

Dengan demikian, jika model hanya dievaluasi berdasarkan akurasi, ada kemungkinan model tampak baik padahal kinerjanya pada kelas minoritas belum memadai. Oleh sebab itu, penilaian yang berdasarkan pada presisi, recall, dan skor F1

macro sangat diperlukan agar dapat mengevaluasi kinerja di ketiga kelas dengan lebih menyeluruh.

5.3 Perbandingan dengan Penelitian atau Pendekatan Sebelumnya

Secara metodologis, penerapan machine learning dalam meramalkan status akademik mahasiswa selaras dengan metode analitik prediktif, yaitu dengan memanfaatkan pola yang terdapat pada data historis untuk menghasilkan prediksi terhadap kelompok tertentu. Dalam kajian ini, fitur yang dianalisis meliputi karakteristik demografis, data penerimaan mahasiswa, situasi ekonomi, serta indikator akademis pada semester pertama.

Keunggulan dari pendekatan ini adalah model dapat menggunakan sejumlah fitur secara bersamaan, sehingga pola prediksi tidak bergantung pada satu variabel saja. Namun, akurasi prediksi tetap sangat bergantung pada kualitas, representatif, dan karakteristik dataset yang digunakan.

Perbandingan hasil akhir dengan penelitian sebelumnya sebaiknya dilakukan setelah mendapatkan nilai evaluasi aktual. Hanya membandingkan algoritma yang digunakan tidaklah memadai, karena perbedaan pada dataset, pra-pemprosesan, pembagian data, fitur, dan metrik dapat menghasilkan performa yang berbeda.

Tabel 1.13. Hasil Perbandingan

Pendekatan	Dataset	Accuracy	Macro F1 - score	Keterangan
DummyClassifier	Dataset penelitian	49,85%	22,18%	Baseline
LogisticRegression	Dataset penelitian	Belum Tersedia	Belum Tersedia	Model Utama
Penelitian Terdahulu 1	Lee & Lee (2023)	Belum Tersedia	Belum Tersedia	Prediksi dropout mahasiswa menggunakan machine learning
Penelitian Terdahulu 2	Chung & Lee (2023)	Belum Tersedia	Belum Tersedia	Prediksi dropout mahasiswa menggunakan pretrained language models

Berdasarkan prinsip klasifikasi evaluasi, sebuah model yang efektif tidak hanya menunjukkan tingkat akurasi yang tinggi, tetapi juga menunjukkan performa yang memuaskan untuk setiap kelas. Maka dari itu, penilaian akhir penelitian akan dilakukan dengan mempertimbangkan gabungan dari metrik, matriks kebingungan, dan analisis kesalahan.

5.4 Interpretasi Hasil

Interpretasi hasil perlu mempertimbangkan situasi di mana model digunakan. Jika Logistic Regression menunjukkan nilai macro F1-score yang lebih tinggi daripada patokan awal, itu berarti model tersebut menunjukkan peningkatan kinerja dibandingkan dengan metode prediksi kelas mayoritas.

Sebaliknya, jika peningkatan dari patokan awal tergolong kecil, model belum menunjukkan nilai tambah yang signifikan jika dibandingkan dengan pendekatan yang lebih sederhana. Situasi ini bisa jadi landasan untuk melakukan eksperimen lebih lanjut, seperti evaluasi fitur, pengolahan data, penanggulangan ketidakseimbangan kelas, atau mencoba algoritma klasifikasi lain.

Hasil dari model tidak dapat digunakan untuk menyatakan bahwa suatu karakteristik mahasiswa secara langsung mengakibatkan mahasiswa mengalami Dropout atau Graduate. Model hanya mempelajari pola yang dapat diprediksi dalam data. Oleh karena itu, interpretasi hasil harus dipisahkan antara prediksi, asosiasi, serta hubungan sebab-akibat.

BAB VI
PENILAIAN RISIKO MODEL

6.1 Privasi Data

Penelitian ini memanfaatkan informasi mahasiswa yang mencakup berbagai karakteristik demografis dan akademis. Beberapa karakteristik seperti kewarganegaraan, jenis kelamin, usia saat mendaftar, status pernikahan, serta latar belakang pendidikan orang tua merupakan informasi yang harus dikelola dengan sangat hati-hati jika terkait dengan individu tertentu. Fitur-fitur tersebut memang dimanfaatkan dalam rancangan eksperimen penelitian.

Dengan demikian, penggunaan dataset harus mengutamakan prinsip privasi. Data yang digunakan untuk analisis seharusnya tidak mengandung identifikasi langsung seperti nama, nomor registrasi mahasiswa, alamat, atau informasi lain yang memungkinkan identifikasi individu secara langsung. Jika data tersebut akan dibagikan, hanya informasi yang relevan untuk kepentingan penelitian yang sebaiknya disertakan.

Hasil dari model juga tidak boleh digunakan untuk mengungkap informasi pribadi dari mahasiswa tertentu. Prediksi harus dianggap sebagai hasil analitis yang memiliki batasan dan bukan sebagai data pribadi yang dapat disebarluaskan tanpa batas.

6.2 Keamanan Data dan Model

Keamanan harus menjadi fokus utama dalam penyimpanan dataset, kode program, hasil prediksi, serta model yang telah dilatih. Akses terhadap informasi ini harus dibatasi hanya untuk individu yang berkepentingan di bidang akademik atau penelitian.

Selain itu, file model dan hasil prediksi juga harus dilindungi dengan baik. Jika model digunakan dalam sistem yang lebih kompleks, akses ke endpoint prediksi harus dibatasi dan aktivitas penggunaannya harus dicatat secara detail.

Aspek keamanan adalah salah satu karakteristik yang sangat penting dalam manajemen risiko AI. NIST AI Risk Management Framework menegaskan pentingnya keamanan, ketahanan, transparansi, privasi, dan keadilan harus diperhatikan selama proses pengembangan dan penggunaan sistem AI.

6.3 Potensi Bias

Potensi adanya bias bisa timbul baik dari kumpulan data maupun proses pembentukan model. Kumpulan data yang dipakai memiliki distribusi kelas yang tidak merata. Kelas Lulusan memiliki proporsi sekitar 50%, sedangkan Kelas Terdaftar hanya sekitar 18% dalam data pelatihan.

Ketidakseimbangan ini dapat membuat model lebih mampu mengenali kelas dengan jumlah data yang lebih banyak. Sebagai akibatnya, meskipun model mungkin menunjukkan akurasi yang cukup tinggi, kinerjanya terhadap kelas tertentu masih dapat tergolong rendah.

Di samping ketidakseimbangan kelas, bias juga bisa muncul berdasarkan atribut demografi. Fitur-fitur seperti jenis kelamin, kewarganegaraan, status pernikahan, pemegang beasiswa, dan internasional digunakan sebagai bagian dari prediktor. Jika terdapat perbedaan signifikan dalam kualitas prediksi di antara kelompok-kelompok tersebut, maka hasil model harus diperiksa lebih mendalam.

6.4 Fairness

Keadilan penting agar model tidak menghasilkan kinerja yang merugikan kelompok tertentu secara tidak seimbang. Pengukuran keadilan bisa dilakukan dengan membandingkan kinerja model berdasarkan kategori demografis yang relevan.

Sebagai ilustrasi, nilai recall untuk kelas Dropout bisa dibandingkan di antara kelompok gender atau antara mahasiswa internasional dan non-internasional. Apabila terlihat perbedaan yang signifikan dalam kinerja, hal tersebut harus dianalisis untuk memahami apakah penyebabnya terkait dengan jumlah data, kualitas fitur, pembagian kelompok, atau karakteristik lainnya.

NIST menyatakan bahwa keadilan dalam sistem kecerdasan buatan berkaitan dengan pengelolaan bias serta kemungkinan munculnya diskriminasi. Bias bisa muncul dari data yang digunakan atau dari proses komputasi, sehingga evaluasinya harus dilakukan dengan pendekatan yang terstruktur.

Tabel 1.14. Rancangan Pemeriksaan Fairness

Aspek	Pemeriksaan
Gender	Membandingkan precision, recall, dan F1-score antar kelompok
Internasional	Membandingkan performa mahasiswa international dan non-international
Scholarship holder	Membandingkan performa penerima dan non-penerima beasiswa
Age at enrollment	Membandingkan performa berdasarkan kelompok usia
Distribusi Data	Memeriksa apakah terdapat kelompok dengan jumlah data sangat kecil

Hasil keadilan seharusnya tidak dipakai untuk menarik kesimpulan tentang adanya diskriminasi tanpa penyelidikan lebih mendalam. Ketidaksamaan kinerja adalah indikasi yang perlu diteliti lebih lanjut dan bukan sebagai bukti langsung bahwa model tersebut terjadi diskriminasi.

6.5 Potensi Penyalahgunaan

Model ramalan status akhir siswa dapat memberikan keuntungan untuk membantu lembaga dalam menganalisis aspek akademis. Namun, ada kemungkinan bahwa model ini dapat disalahgunakan jika hasil ramalannya dipakai sebagai dasar keputusan otomatis untuk siswa.

Sebagai ilustrasi, ramalan tentang Dropout seharusnya tidak langsung dijadikan alasan untuk memberikan hukuman, mengurangi hak siswa, atau membuat keputusan akademis tanpa pemeriksaan lanjutan. Hasil ramalan dari model ini sebaiknya dipakai sebagai informasi tambahan untuk mendeteksi siswa yang mungkin memerlukan perhatian atau dukungan lebih.

Dengan demikian, model ini tidak sepatutnya menggantikan keputusan yang diambil oleh manusia. Hasil ramalan harus dipertimbangkan bersama informasi lainnya dan dikonfirmasi melalui mekanisme evaluasi yang tepat.

6.6 Pihak yang Terdampak

Pihak yang mungkin terpengaruh oleh penerapan model terdiri dari:

1. Mahasiswa, karena hasil prediksi dapat mempengaruhi cara lembaga memahami situasi akademik mereka.
2. Dosen atau penasihat akademik, karena hasil dari model bisa dimanfaatkan sebagai informasi tambahan dalam proses pendampingan.
3. Perguruan tinggi, karena model berfungsi sebagai alat bantu dalam analisis dan pengambilan keputusan.
4. Pengelola data, karena memiliki tanggung jawab terhadap keamanan dan privasi data mahasiswa.
5. Peneliti atau pengembang model, karena bertanggung jawab untuk memastikan kualitas, batasan, dan dokumentasi dari model tersebut.

Setiap pihak memiliki kepentingan yang berbeda, sehingga penerapan model harus mempertimbangkan dampaknya bagi semua pihak yang terlibat.

6.7 Residual Risk

Meskipun data sudah dibagi dengan pendekatan stratifikasi dan tidak ada tumpang tindih antar subset, tetap ada potensi risiko pada model. Dataset telah diatur menjadi 70% untuk pelatihan, 15% untuk validasi, dan 15% untuk pengujian, serta menggunakan random seed 42. Penilaian tumpang tindih juga menunjukkan bahwa tidak terdapat data yang sama di antara subset.

Namun, ada beberapa risiko residual yang可能 masih muncul, yaitu:

1. Kesalahan model, di mana model mungkin memberikan prediksi yang keliru.
2. Ketidakseimbangan kelas, terutama karena jumlah kelas Enrolled lebih sedikit dibandingkan dengan Graduate.

3. Bias dataset, jika ciri-ciri data tidak sepenuhnya mencerminkan populasi mahasiswa.
4. Perubahan data, jika karakteristik mahasiswa di masa mendatang berbeda dari data yang digunakan dalam pelatihan.
5. Risiko keadilan, jika kinerja model beragam dengan signifikan di antara kelompok demografis.
6. Risiko penyalahgunaan, jika hasil prediksi dianggap sebagai keputusan akhir tanpa ada validasi manusia.
7. Risiko privasi, jika informasi mahasiswa atau hasil prediksi bisa diakses oleh pihak yang tidak berwenang.

NIST AI RMF menekankan perlunya pengukuran dan pencatatan risiko, termasuk risiko privasi serta keadilan dan bias.

6.8 Strategi Mitigasi Risiko

Untuk menekan kemungkinan risiko, ada beberapa tindakan mitigasi yang bisa diambil, yaitu:

1. Menggunakan lebih dari satu metrik dalam mengevaluasi model.
2. Menganalisis confusion matrix serta kesalahan dalam prediksi di masing-masing kategori.
3. Melakukan penilaian terhadap kinerja berdasarkan kelompok demografi yang relevan.
4. Menjaga kerahasiaan serta keamanan dari dataset yang ada.
5. Tidak menjadikan prediksi model sebagai satu-satunya acuan dalam pengambilan keputusan terhadap mahasiswa.
6. Melakukan penilaian ulang jika model diterapkan pada data dari waktu yang berbeda.

7. Mendokumentasikan semua parameter, random seed, versi data, hasil penilaian, dan batasan dari model tersebut.

8. Melakukan pengawasan terhadap perubahan distribusi data setelah implementasi model.

Dengan langkah-langkah tersebut, model dapat diterapkan dengan lebih bertanggung jawab dan risiko yang tersisa dapat dipantau secara terus-menerus.

6.9 Kesimpulan Penilaian Risiko

Model pengklasifikasian dalam studi ini menunjukkan peluang untuk mendukung evaluasi status akhir mahasiswa berdasarkan informasi demografis dan akademis. Namun, hasil yang diperoleh harus diinterpretasikan sebagai alat analisis dan bukan sebagai keputusan akhir.

Risiko utama timbul dari kesalahan dalam prediksi, ketidakseimbangan antara kelas, potensi adanya bias demografi, isu privasi data, serta kemungkinan penyalahgunaan hasil model. Maka dari itu, penggunaan model harus disertai dengan penilaian kinerja, pemeriksaan keadilan, perlindungan data, dokumentasi, dan pengawasan manusia.

DAFTAR PUSTAKA

National Institute of Standards and Technology. (2023). *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*. U.S. Department of Commerce. NIST AI Risk Management Framework

National Institute of Standards and Technology. (2023). *AI Risk Management Framework FAQs*. U.S. Department of Commerce. NIST AI RMF FAQs

scikit-learn developers. (2026). *LogisticRegression — scikit-learn 1.9.1 documentation*. scikit-learn LogisticRegression Documentation

scikit-learn developers. (2026). *Metrics and scoring: quantifying the quality of predictions — scikit-learn 1.9.1 documentation*. scikit-learn Model Evaluation Documentation

scikit-learn developers. (2026). *classification_report — scikit-learn 1.9.1 documentation*. scikit-learn Classification Report Documentation