ANALISIS STATUS AKHIR MAHASISWA MENGGUNAKAN DATA DEMOGRAFI DAN AKADEMIK

Fanisa Zahira Priyanka[1], Lulu Solikha[2]

Program Studi Sistem Informasi, Fakultas Ilmu Komputer, Universitas Singaperbangsa Karawang

Pengantar Big Data · 2026

Abstrak

Status akhir mahasiswa merupakan informasi penting untuk memahami pola keberhasilan studi dan mengidentifikasi kelompok yang mungkin membutuhkan dukungan akademik. Penelitian ini menganalisis karakteristik demografi, sosial-ekonomi, dan akademik mahasiswa serta menyusun pendekatan klasifikasi untuk memprediksi status akhir yang terdiri atas Dropout, Enrolled, dan Graduate. Data berasal dari dataset Predict Students' Dropout and Academic Success pada UCI Machine Learning Repository, yang berisi 4.424 observasi dan 37 kolom, yaitu 36 fitur prediktor serta satu variabel target. Tahapan penelitian meliputi pemeriksaan kualitas data, analisis eksploratif, penetapan fitur, pembagian data secara stratified menjadi training, validation, dan testing dengan proporsi 70:15:15, serta evaluasi DummyClassifier sebagai baseline dan Logistic Regression sebagai model utama. Pembagian data menggunakan random_state=42. Pada subset testing, baseline menghasilkan accuracy 49,85%, macro precision 16,62%, macro recall 33,33%, dan macro F1-score 22,18%. Nilai evaluasi Logistic Regression yang tercatat belum dapat digunakan karena seluruh metrik muncul sebagai nol dan perlu diverifikasi melalui eksekusi ulang. Oleh karena itu, kesimpulan perbandingan model belum ditetapkan. Penelitian ini menekankan evaluasi melalui beberapa metrik dan interpretasi yang berhati-hati agar hasil prediksi tidak disamakan dengan hubungan sebab-akibat.

Kata kunci: status akhir mahasiswa; klasifikasi multikelas; machine learning; analisis data pendidikan; dropout

1. Pendahuluan

Keberlanjutan studi mahasiswa merupakan salah satu isu yang relevan bagi perguruan tinggi. Status akhir mahasiswa dapat berkaitan dengan berbagai karakteristik, mulai dari latar belakang demografi dan sosial-ekonomi hingga pengalaman akademik. Analisis berbasis data dapat membantu mengenali pola dalam karakteristik tersebut dan menjadi bahan pertimbangan untuk merancang dukungan akademik. Namun, hasil analisis prediktif perlu digunakan secara hati-hati dan tidak dapat menggantikan penilaian manusia dalam pengambilan keputusan.

Penelitian ini menggunakan dataset Predict Students' Dropout and Academic Success yang tersedia melalui UCI Machine Learning Repository. Dataset tersebut berisi informasi demografi, jalur pendaftaran, latar belakang pendidikan, status sosial-ekonomi, indikator makroekonomi, dan capaian akademik. Variabel target, `Target`, memiliki tiga kategori: Dropout, Enrolled, dan Graduate. Dokumentasi dataset menyatakan bahwa data memiliki 4.424 observasi dan dilisensikan dengan Creative Commons Attribution 4.0 International (Realinho et al., 2021).

Sejumlah penelitian terdahulu telah menerapkan machine learning untuk prediksi dropout mahasiswa. Cho et al. (2023) membandingkan beberapa algoritma klasifikasi dan teknik penanganan ketidakseimbangan kelas, sedangkan Won et al. (2023) mengembangkan pendekatan prediksi menggunakan pretrained language models dengan informasi demografi dan akademik. Penelitian ini menggunakan dataset UCI tersebut untuk mengeksplorasi distribusi status akhir dan menguji pendekatan klasifikasi multikelas dengan baseline sederhana.

Tujuan penelitian ini adalah (1) mendeskripsikan distribusi status akhir dan karakteristik data; (2) menyiapkan data dan fitur yang relevan untuk klasifikasi; serta (3) mengevaluasi kemampuan model klasifikasi dengan memperhatikan kinerja keseluruhan dan setiap kelas. Karena distribusi target tidak seimbang, evaluasi tidak hanya bertumpu pada accuracy, tetapi juga mempertimbangkan macro precision, macro recall, macro F1-score, dan confusion matrix.

2. Tinjauan Pustaka

2.1 Analisis data pendidikan

Analisis data eksploratif (Exploratory Data Analysis/EDA) digunakan untuk memahami struktur, distribusi, dan pola awal dalam dataset sebelum pemodelan dilakukan. Pendekatan ini meliputi pemeriksaan statistik deskriptif, distribusi kelas, serta hubungan antarvariabel melalui visualisasi. Tukey (1977) menekankan peran eksplorasi sebagai cara untuk mempelajari data dan mengidentifikasi pola yang perlu ditinjau lebih lanjut. Dalam penelitian ini, EDA digunakan untuk menggambarkan data, bukan untuk membuktikan hubungan sebab-akibat.

2.2 Klasifikasi multikelas dan evaluasi

Klasifikasi multikelas bertujuan memetakan setiap observasi ke salah satu dari lebih dari dua kategori. Pada penelitian ini, kategori yang diprediksi adalah Dropout, Enrolled, dan Graduate. DummyClassifier dengan strategi most_frequent berfungsi sebagai baseline yang memprediksi kelas mayoritas berdasarkan data pelatihan. Logistic Regression digunakan sebagai model utama dengan parameter max_iter=2000.

Accuracy menunjukkan proporsi prediksi yang benar dari seluruh observasi. Precision mengukur ketepatan prediksi untuk suatu kelas, sedangkan recall menunjukkan kemampuan model menemukan observasi yang benar-benar termasuk dalam kelas tersebut. Macro F1-score menghitung rata-rata F1-score setiap kelas dengan bobot yang sama sehingga hasilnya tidak terlalu didominasi kelas mayoritas. Confusion matrix membantu memperlihatkan pola prediksi benar dan salah antarkelas.

3. Metode Penelitian

3.1 Data dan unit analisis

Data penelitian berasal dari dataset Predict Students' Dropout and Academic Success pada UCI Machine Learning Repository (Realinho et al., 2021). Unit analisis adalah mahasiswa, dengan satu baris merepresentasikan satu observasi mahasiswa. Dataset mentah terdiri atas 4.424 baris dan 37 kolom, yaitu 36 fitur prediktor dan satu variabel target bernama `Target`. File data menggunakan delimiter titik koma. Fitur mencakup karakteristik pendaftaran, demografi, pendidikan dan pekerjaan orang tua, status beasiswa dan pembayaran biaya kuliah, capaian akademik semester pertama, serta indikator makroekonomi.

Tabel 1. Ringkasan dataset penelitian

Aspek	Keterangan
Nama dataset	Predict Students' Dropout and Academic Success
Sumber	UCI Machine Learning Repository
Jumlah observasi	4.424 mahasiswa
Jumlah kolom	37 (36 fitur dan 1 target)
Variabel target	Target
Kategori target	Dropout, Enrolled, Graduate
Lisensi	Creative Commons Attribution 4.0 International (CC BY 4.0)

3.2 Pemeriksaan dan persiapan data

Persiapan data meliputi pemeriksaan nama dan jumlah kolom, tipe data, nilai kosong, duplikasi, rentang atau kategori nilai, serta distribusi variabel target. Data mentah dipertahankan sebagai sumber acuan, sementara hasil pemrosesan disimpan terpisah. Variabel yang tersimpan sebagai kode angka dipahami berdasarkan makna konseptualnya; kode kategori tidak otomatis diperlakukan sebagai besaran

numerik kontinu. Tahap ini juga mencakup pemeriksaan agar variabel target tidak ikut dimasukkan ke dalam fitur prediktor.

3.3 Eksplorasi data

EDA dirancang untuk meninjau distribusi kelas target, statistik deskriptif fitur numerik, karakteristik akademik berdasarkan status akhir, karakteristik demografi dan sosial-ekonomi, serta korelasi antarvariabel numerik. Visualisasi yang relevan meliputi grafik distribusi target, perbandingan capaian akademik antarkelas, dan heatmap korelasi. Interpretasi hasil hanya dilakukan terhadap pola yang terlihat pada hasil analisis aktual; korelasi atau perbedaan distribusi tidak ditafsirkan sebagai bukti kausal.

3.4 Pemilihan fitur dan pembagian data

Kolom `Target` ditetapkan sebagai label klasifikasi. Sebanyak 30 fitur digunakan dalam rancangan eksperimen, mencakup informasi pendaftaran, demografi, latar belakang keluarga, status keuangan, capaian akademik semester pertama, dan indikator makroekonomi. Dataset dibagi secara stratified menjadi 70% data training, 15% validation, dan 15% testing menggunakan random_state=42. Data training digunakan untuk melatih model, validation untuk membantu pemilihan model, dan testing untuk evaluasi akhir. Pemeriksaan yang tercatat menunjukkan tidak ada tumpang tindih observasi di antara ketiga subset.

Tabel 2. Pembagian dataset

Subset	Jumlah observasi	Proporsi	Fungsi
Training	3.096	70%	Melatih model
Validation	664	15%	Membantu pemilihan dan perbandingan model
Testing	664	15%	Evaluasi akhir
Total	4.424	100%	—

Tabel 3. Distribusi kelas pada setiap subset

Subset	Dropout	Enrolled	Graduate
Training	32,11%	17,96%	49,94%
Validation	32,08%	17,92%	50,00%
Testing	32,23%	17,92%	49,85%

3.5 Model dan parameter

Model baseline menggunakan DummyClassifier(strategy="most_frequent"), yang selalu memprediksi kelas mayoritas dalam data pelatihan. Model utama menggunakan LogisticRegression(max_iter=2000). Pembandingan dilakukan dengan metrik klasifikasi yang sama. Parameter pembagian data ditetapkan dengan random_state=42 agar pembagian dapat direproduksi. Nilai metrik model utama hanya dapat dilaporkan setelah keluaran evaluasi diperiksa dan dipastikan berasal dari prediksi pada subset yang benar.

3.6 Metrik evaluasi

Evaluasi menggunakan accuracy, macro precision, macro recall, dan macro F1-score. Macro F1-score digunakan untuk memberi bobot setara pada ketiga kelas, sementara recall kelas Dropout penting untuk mengetahui seberapa banyak mahasiswa dalam kelas tersebut berhasil dikenali. Confusion matrix digunakan untuk meninjau pola kesalahan klasifikasi. Metrik pada data testing dipakai sebagai evaluasi akhir dan tidak digunakan untuk memilih model atau mengubah parameter.

4. Hasil

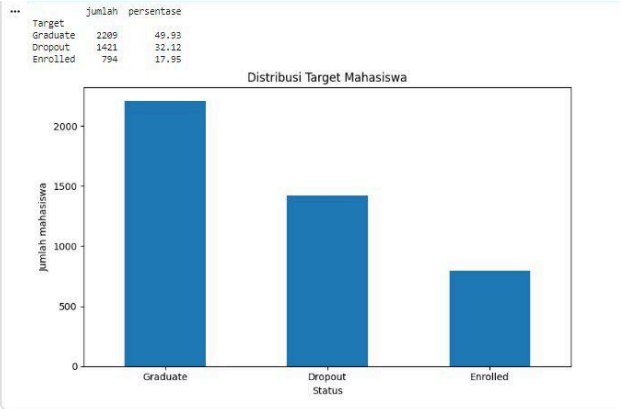
4.1 Distribusi status akhir mahasiswa

Dataset memuat tiga kelas status akhir. Berdasarkan jumlah observasi yang tercatat, 1.421 mahasiswa termasuk kelas Dropout, 794 termasuk Enrolled, dan 2.209 termasuk Graduate. Graduate merupakan kelas terbesar, sedangkan Enrolled merupakan kelas terkecil. Proporsi yang tidak sama menunjukkan bahwa evaluasi perlu memperhatikan kinerja pada setiap kelas dan tidak cukup hanya menggunakan accuracy.

Tabel 4. Distribusi kelas target

Status akhir	Jumlah	Proporsi
Dropout	1.421	32,12%
Enrolled	794	17,95%
Graduate	2.209	49,93%
Total	4.424	100,00%

Gambar 1. Distribusi status akhir mahasiswa



4.2 Hasil pembagian data

Pembagian stratified menghasilkan 3.096 observasi untuk training, 664 untuk validation, dan 664 untuk testing. Proporsi kelas pada ketiga subset tetap mendekati distribusi dataset secara keseluruhan. Pemeriksaan tumpang tindih yang dicatat juga menunjukkan tidak ada observasi yang digunakan secara bersamaan pada pasangan subset training-validation, training-testing, maupun validation-testing. Hal ini mendukung pemisahan data yang diperlukan untuk mengevaluasi model secara lebih objektif.

4.3 Evaluasi model klasifikasi

Pada data testing, DummyClassifier menghasilkan accuracy sebesar 49,85%, macro precision 16,62%, macro recall 33,33%, dan macro F1-score 22,18%. Hasil ini konsisten dengan karakteristik baseline yang selalu memilih kelas mayoritas. Nilai macro precision dan macro F1-score yang rendah menunjukkan bahwa baseline tidak memberikan prediksi yang seimbang untuk ketiga kelas.

Tabel 5. Kinerja baseline pada data testing

Metrik	Nilai
Accuracy	49,85%
Macro precision	16,62%
Macro recall	33,33%
Macro F1-score	22,18%

Keluaran evaluasi Logistic Regression menunjukkan nilai nol untuk seluruh metrik. Nilai tersebut tidak dapat ditafsirkan sebagai kinerja model yang sah tanpa memeriksa kembali proses prediksi dan perhitungan metrik. Oleh karena itu, hasil Logistic Regression tidak digunakan untuk menyimpulkan model mana yang lebih baik. Perbandingan akhir baru dapat dibuat setelah model dijalankan ulang dan hasilnya diverifikasi.

Tabel 6. Status verifikasi hasil perbandingan model

Model	Status hasil	Catatan
DummyClassifier	Tersedia	Metrik testing tercatat dan digunakan sebagai baseline
Logistic Regression	Belum tervalidasi	Keluaran metrik sebelumnya seluruhnya nol; perlu menjalankan ulang evaluasi

4.4 Hasil eksplorasi fitur

Analisis eksploratif diarahkan pada perbandingan karakteristik akademik, demografi, dan sosial-ekonomi antarstatus akhir. Namun, ringkasan numerik atau visual yang cukup untuk menyatakan fitur tertentu sebagai pola paling menonjol belum tersedia secara konsisten dalam materi yang diperiksa. Karena itu, artikel ini tidak menetapkan fitur terpenting atau menyatakan bahwa karakteristik tertentu menyebabkan dropout. Temuan pada bagian ini perlu dilengkapi dengan grafik dan angka hasil eksekusi final.

5. Pembahasan

Distribusi status akhir menunjukkan bahwa kelas Graduate mencakup sekitar separuh observasi, sedangkan Enrolled memiliki proporsi paling kecil. Ketidakseimbangan ini membuat penggunaan accuracy saja berpotensi memberikan gambaran yang kurang lengkap tentang kemampuan model. Nilai baseline memperlihatkan hal tersebut: meskipun accuracy mencapai 49,85%, macro F1-score hanya 22,18%, karena prediksi kelas mayoritas tidak memberikan kinerja yang seimbang pada kelas lainnya.

Secara konseptual, Logistic Regression dapat digunakan sebagai pendekatan klasifikasi yang relatif sederhana, sedangkan baseline diperlukan untuk mengetahui apakah model utama memberikan peningkatan dibandingkan strategi prediksi kelas mayoritas. Akan tetapi, karena nilai evaluasi Logistic Regression yang tersedia belum valid, penelitian ini belum dapat menyatakan bahwa model tersebut lebih baik atau lebih buruk daripada baseline. Kesimpulan mengenai kinerja model perlu menunggu evaluasi ulang yang menggunakan data testing dan prosedur perhitungan metrik yang benar.

Hasil penelitian juga harus dipahami dalam batas konteks dataset. Pola statistik dan prediksi model menunjukkan keterkaitan yang dapat dipelajari dari data, tetapi tidak membuktikan bahwa variabel demografi, sosial-ekonomi, atau akademik tertentu menyebabkan mahasiswa berhenti kuliah. Jika pendekatan ini dikembangkan menjadi sistem pendukung peringatan dini, hasilnya sebaiknya digunakan sebagai informasi tambahan untuk pendampingan, bukan sebagai dasar keputusan otomatis. Privasi, potensi bias, perbedaan kinerja antar kelompok, dan perubahan karakteristik data dari waktu ke waktu perlu dipertimbangkan (National Institute of Standards and Technology, 2023).

6. Keterbatasan Penelitian

Penelitian ini memiliki beberapa keterbatasan. Pertama, dataset berasal dari konteks pendidikan tinggi di Portugal sehingga hasilnya tidak dapat langsung digeneralisasikan ke institusi atau negara lain. Kedua, distribusi kelas target tidak seimbang, terutama karena jumlah observasi Enrolled lebih kecil daripada Graduate. Ketiga, hasil evaluasi Logistic Regression belum dapat diverifikasi sehingga perbandingan model dan penentuan model terbaik belum dapat diselesaikan. Keempat, visualisasi dan ringkasan hasil EDA

perlu dipastikan berasal dari eksekusi final yang sama dengan kode dan data dalam repositori. Terakhir, hasil prediksi tidak menjelaskan hubungan sebab-akibat dan belum menggantikan kebutuhan untuk menguji fairness atau kestabilan model pada data lain.

7. Kesimpulan

Penelitian ini menganalisis dataset Predict Students' Dropout and Academic Success yang terdiri atas 4.424 observasi, 36 fitur prediktor, dan satu variabel target dengan tiga kelas: Dropout, Enrolled, dan Graduate. Kelas Graduate merupakan kelas terbesar dengan 2.209 observasi (49,93%), sedangkan Enrolled merupakan kelas terkecil dengan 794 observasi (17,95%). Dataset dibagi secara stratified menjadi training, validation, dan testing dengan proporsi 70:15:15 dan random_state=42. Baseline DummyClassifier menghasilkan accuracy 49,85% dan macro F1-score 22,18% pada data testing. Karena hasil evaluasi Logistic Regression belum valid, belum dapat disimpulkan apakah model utama meningkatkan kinerja dibandingkan baseline. Sebelum penelitian dinyatakan final, evaluasi Logistic Regression perlu dijalankan ulang dan diverifikasi, sedangkan grafik EDA harus diselaraskan dengan keluaran kode final. Secara umum, analisis ini menunjukkan pentingnya menilai kinerja klasifikasi melalui beberapa metrik serta menggunakan hasil prediksi secara hati-hati dalam konteks pendidikan.

8. Deklarasi

Ketersediaan data dan kode

Dataset Predict Students' Dropout and Academic Success tersedia melalui UCI Machine Learning Repository dengan DOI https://doi.org/10.24432/C5MC89 dan lisensi CC BY 4.0. Kode, dokumentasi, dan berkas pendukung proyek kelompok direncanakan tersedia pada repositori GitHub: https://github.com/priyankazhr/Proyek-Big-Data-Kelompok-9. README dan berkas environment pada repositori perlu dipastikan memuat langkah menjalankan proyek dari lingkungan baru serta menghasilkan keluaran yang sesuai dengan artikel.

Kontribusi penulis

Fanisa Zahira Priyanka dan Lulu Solikha berkontribusi pada pengerjaan proyek dan penyusunan artikel. Anggota kelompok membagi pekerjaan pada pengelolaan repository, dokumentasi, EDA, pemodelan, evaluasi, dan penyusunan artikel sesuai pembagian tugas kelompok.

Konflik kepentingan

Penulis menyatakan tidak terdapat konflik kepentingan yang berkaitan dengan penelitian ini.

Pendanaan

Penelitian ini dikerjakan sebagai bagian dari tugas mata kuliah Pengantar Big Data. Tidak ada informasi pendanaan eksternal yang tercantum dalam materi penelitian yang diperiksa.

Daftar Pustaka

Cho, C. H., Yu, Y. W., & Kim, H. G. (2023). A study on dropout prediction for university students using machine learning. *Applied Sciences, 13*(21), Article 12004. https://doi.org/10.3390/app132112004

National Institute of Standards and Technology. (2023). *Artificial intelligence risk management framework (AI RMF 1.0)* (NIST AI 100-1). U.S. Department of Commerce. https://doi.org/10.6028/NIST.AI.100-1

Realinho, V., Vieira Martins, M., Machado, J., & Baptista, L. (2021). *Predict students' dropout and academic success* [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C5MC89

Tukey, J. W. (1977). *Exploratory data analysis*. Addison-Wesley.

Won, H.-S., Kim, M.-J., Kim, D., Kim, H.-S., & Kim, K.-M. (2023). University student dropout prediction using pretrained language models. *Applied Sciences, 13*(12), Article 7073. https://doi.org/10.3390/app13127073